

**LAPORAN UAS
ANALISIS RUNTUN WAKTU**



Dosen Pengampu:

Sri Utami Zuliana, S.Si., M.Sc., Ph.D.

Oleh:

Muhammad Sirojuddin

(23106010092)

**FAKULTAS SAINS DAN TEKNOLOGI
UIN SUNAN KALIJAGA
YOGYAKARTA
2026**

DAFTAR ISI

DAFTAR ISI.....	2
BAB I.....	5
PENDAHULUAN.....	5
1.1 Latar Belakang.....	5
1.2 Rumusan Masalah.....	5
1.3 Tujuan Penelitian.....	6
BAB II.....	7
DASAR TEORI.....	7
2.1. Stasioneritas.....	7
2.1.1. Definisi Stasioneritas.....	7
2.1.2. Dampak Ketidakstasioneran.....	7
2.1.3. Uji Stasioneritas Secara Visual.....	7
2.1.4. Transformasi Menuju Stasioneritas.....	7
2.2 Model Moving Average (MA(q)).....	8
2.2.1 Persamaan Dasar.....	8
2.2.2 Sifat Statistik Utama.....	8
2.2.3 Identifikasi Orde q (Plot ACF).....	8
2.3 Model Autoregressive (AR(p)).....	9
2.3.1 Persamaan Umum.....	9
2.3.2 Syarat Kausalitas dan Stasioneritas.....	9
Fungsi Autokorelasi (ACF) dan Persamaan Yule-Walker.....	9
2.4 Model Mixed Autoregressive-Moving Average (ARMA(p, q)).....	10
2.4.1 Persamaan Umum.....	10
2.4.2 Kondisi Stasioneritas dan Invertibilitas.....	10
2.4.3 Identifikasi Pola (ACF dan PACF).....	10
2.5. Differencing (d).....	11
2.5.1 Mekanisme Matematis.....	11
2.5.2 Dampak Terhadap Data (Transformasi Menuju Stasioner).....	11
2.6 Model ARIMA(p,d,q) dengan d=1.....	11
2.6.1 Formulasi Model ARIMA(p,1,q).....	12
2.6.2 Representasi Operator Huruf Backshift.....	12
2.7 Diagnostik Model dan Pemilihan Model Terbaik.....	12
2.7.1. Diagnostik Residual (Sisaan).....	12
A. Asumsi White Noise (Ketidakgantungan Residual).....	13
B. Asumsi Normalitas Residual.....	13
2.7.2. Kriteria Pemilihan Model Terbaik (AIC).....	13
BAB III.....	15

METODOLOGI PENELITIAN.....	15
3.1 Metode Pengumpulan Data.....	15
3.2 Pemeriksaan Kestasioneran Data Asli.....	15
3.3 Model Moving Average Murni.....	15
3.4 Model Autoregressive Murni.....	16
3.5 Transformasi Pembedaan Pertama.....	16
3.6. Model ARMA(p,q).....	16
3.7 Model ARIMA(p,d,q) dengan d=1.....	17
3.8 Pemilihan Model Terbaik.....	17
BAB 4.....	18
HASIL DAN PEMBAHASAN.....	18
4.1 Deskripsi dan Karakteristik Visual Data.....	18
4.1.1 Plot Data Aktual Volume Kendaraan Harian.....	18
4.1.2 Orde Orde Pembobotan SMA.....	19
4.1.3 Analisis Kestasioneran Berdasarkan Grafik (ACF dan PACF).....	20
4.1.4 Evaluasi Stasioneritas Setelah Transformasi Differencing.....	21
4.2 Estimasi Parameter dan Diagnostik.....	22
4.2.1 Model Moving Average Orde Satu (MA(1)).....	22
4.2.2 Model Moving Average Orde Dua (MA(2)).....	24
4.2.3 Model Autoregressive Orde Satu (AR(1)).....	26
4.2.4 Model Autoregressive Orde Dua (AR(2)).....	27
4.3 Estimasi Parameter dan Diagnostik Model Campuran ARMA(p,q).....	29
4.3.1 Model ARMA(1,1).....	29
4.3.2 Model ARMA(1,2).....	30
4.3.3 Model ARMA(2,1).....	32
4.3.4 Model ARMA(2,2).....	34
4.4 penerapan Model ARIMA dengan d=1.....	35
4.4.1 Model ARIMA(0,1,1).....	35
4.4.2 Model ARIMA(1,1,1).....	37
4.4.3 Model ARIMA(2,1,1).....	38
4.4.4 Model ARIMA(1,1,2).....	39
4.4.5 Model ARIMA(2,1,2).....	40
4.5 Pemilihan Model Terbaik dan Peramalan (Forecasting).....	42
4.5.1 Analisis Kurva Nilai Kecocokan (Fitted Values) Model Terbaik.....	43
4.5.2 Proyeksi Peramalan Jangka Pendek (Forecasting).....	44
BAB 5.....	45
KESIMPULAN DAN SARAN.....	45
5.1 Kesimpulan.....	45
5.2 Saran.....	45

DAFTAR PUSTAKA.....	47
LAMPIRAN.....	48
INPUT.....	48
OUTPUT.....	51

BAB I

PENDAHULUAN

1.1 Latar Belakang

Perkembangan mobilitas urban yang pesat di Provinsi Daerah Istimewa Yogyakarta (DIY) membawa dampak signifikan terhadap beban kapasitas jaringan jalan raya. Salah satu titik krusial yang mengalami fluktuasi volume arus lalu lintas cukup dinamis adalah Simpang Wardhani. Sebagai salah satu persimpangan strategis, pergerakan kendaraan di area ini—khususnya kendaraan roda 4 yang melakukan manuver berbelok ke arah kanan—sering kali memicu titik jenuh (*bottleneck*) yang berdampak pada antrean panjang, peningkatan emisi gas buang, hingga potensi gangguan kelancaran lalu lintas pada jam-jam tertentu.

Untuk merumuskan strategi manajemen rekayasa lalu lintas yang efektif, seperti penentuan durasi siklus lampu APILL (Alat Pemberi Isyarat Lalu Lintas) maupun kebijakan pembatasan volume jalan, diperlukan suatu pemodelan statistik yang mampu memahami karakteristik historis dan memproyeksikan volume lalu lintas secara akurat dalam jangka pendek. Dinamika volume lalu lintas harian pada dasarnya merupakan data deret waktu (*time series*) yang memiliki pola fluktuasi acak, memori jangka pendek, maupun ketergantungan stokastik pada periode-periode sebelumnya.

Melalui pemanfaatan teknologi observasi tidak langsung, Dinas Perhubungan Provinsi DIY telah menyediakan akses rekaman CCTV secara *real-time* melalui situs resmi cctv.jogjaprov.go.id. Data sekunder berbasis visual ini memberikan peluang besar untuk melakukan pencatatan volume kendaraan secara rigid, khususnya pada interval kritis pukul 20.00 hingga 20.03 WIB dari tanggal 20 April 2026 sampai dengan 20 Mei 2026. Pengamatan pada durasi pendek ini penting untuk mengevaluasi karakteristik kejutan arus kendaraan (*traffic shock*) pasca-jam sibuk malam hari.

Dalam memodelkan data runtun waktu yang fluktuatif dan memiliki memori dependensi kompleks seperti ini, Metodologi Box-Jenkins melalui model *Autoregressive Moving Average* (ARMA) maupun *Autoregressive Integrated Moving Average* (ARIMA) terbukti menjadi instrumen prediktif yang sangat kuat. Pendekatan ini bekerja secara empiris berdasarkan data itu sendiri (*let the data speak for themselves*) tanpa membutuhkan asumsi struktural yang kaku. Dengan mengevaluasi sekumpulan model kandidat murni maupun campuran, penelitian ini diharapkan mampu menyajikan model terbaik yang memiliki parameter paling efisien (prinsip parsimoni) dan sisaan acak murni (*white noise*) demi menghasilkan proyeksi manajemen lalu lintas yang akurat di Simpang Wardhani.

1.2 Rumusan Masalah

Berdasarkan pemaparan latar belakang di atas, rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana karakteristik visual, pola fluktuasi, dan status kestasioneran data harian volume lalu lintas kendaraan roda 4 yang berbelok ke kanan di Simpang Wardhani periode 20 April 2026 sampai dengan 20 Mei 2026?
2. Bagaimana estimasi parameter dan bentuk persamaan formal dari sekumpulan model kandidat murni tanpa pembedaan—AR(1), AR(2), MA(1), MA(2)—serta model campuran ARMA(p,q) dan model ARIMA(p,1,q) dengan pembedaan pertama?

3. Model manakah yang sisaannya lolos uji diagnostik acak murni (*white noise*) serta distribusi normal, dan model manakah yang terpilih sebagai model terbaik berdasarkan kriteria informasi *Akaike Information Criterion* (AIC)?
4. Bagaimana hasil proyeksi peramalan jangka pendek untuk 7 periode ke depan menggunakan model terbaik tersebut, serta bagaimana interpretasi fisis nilainya dalam konteks manajemen lalu lintas nyata?

1.3 Tujuan Penelitian

Adapun tujuan yang ingin dicapai melalui pelaksanaan penelitian ini adalah:

1. Mengidentifikasi karakteristik visual, pola osilasi, tren, serta status kestasioneran data aktual volume lalu lintas harian kendaraan roda 4 di Simpang Wardhani sebelum dan sesudah transformasi *differencing* tingkat pertama.
2. Mengestimasi parameter dan menyusun persamaan matematika formal dari seluruh variasi orde model kandidat AR, MA, ARMA, dan ARIMA yang diuji menggunakan RStudio.
3. Melakukan pengujian diagnostik secara rigid terhadap sisaan model menggunakan uji Ljung-Box dan visualisasi histogram-kurva normal untuk menyaring model yang memenuhi asumsi, serta menetapkan model terbaik berdasarkan nilai AIC terkecil.
4. Menghasilkan proyeksi peramalan *point forecast* beserta rentang ketidakpastiannya (interval kepercayaan 80% dan 95%) untuk 7 periode ke depan sebagai referensi ilmiah dalam pengambilan keputusan rekayasa lalu lintas di Simpang Wardhani.

BAB II

DASAR TEORI

2.1. Stasioneritas

Dalam analisis deret waktu (*time series*), stasioneritas adalah syarat fundamental yang harus dipenuhi sebelum data dapat dimodelkan menggunakan pendekatan ARIMA. Secara konseptual, data dikatakan stasioner jika sifat statistiknya tidak berubah seiring berjalannya waktu.

2.1.1. Definisi Stasioneritas

Sebuah proses stokastik $\{y_t\}$ dikatakan stasioner secara lemah (*weakly stationary*) jika memenuhi tiga kriteria utama:

5. Mean Konstan: $E(y_t) = \mu$ untuk semua t . Nilai rata-rata deret waktu tidak menunjukkan tren naik atau turun.
6. Varians Konstan: $Var(y_t) = E(y_t - \mu)^2 = \sigma^2$ untuk semua t . Variabilitas data tidak melebar atau menyempit seiring waktu (tidak ada heteroskedastisitas).
7. Autokovarians Bergantung pada Lag: $Cov(y_t, y_{t-k}) = \gamma_k$, yang artinya kovarians antara observasi saat ini dengan nilai lampau hanya bergantung pada jarak waktu (*lag k*), bukan pada waktu spesifik t di mana observasi tersebut terjadi.

2.1.2. Dampak Ketidakstasioneran

Jika data tidak stasioner, analisis statistik konvensional akan menghasilkan estimasi yang menyesatkan (*spurious regression*). Dokumen Anda menekankan bahwa:

5. Tren: Kehadiran tren membuat mean tidak konstan, sehingga ACF dari data tersebut akan melandai turun secara sangat lambat (*die out slowly*).
6. Unit Root: Keberadaan *unit root* (akar unit) menyebabkan gangguan acak (*random shock*) memiliki dampak permanen terhadap level data, mengubah model menjadi proses *Random Walk* ($y_t = y_{t-1} + \epsilon_t$), yang merupakan bentuk ekstrem dari ketidakstasioneran.

2.1.3. Uji Stasioneritas Secara Visual

Metode paling mendasar untuk mendeteksi stasioneritas adalah melalui pemeriksaan visual:

- Plot Runtun Waktu: Jika plot menunjukkan tren (linear atau non-linear) atau pola musiman yang jelas, data tersebut hampir pasti tidak stasioner.
- Plot ACF: Jika plot ACF dari data asli meluruh sangat lambat terhadap lag, ini adalah indikasi kuat adanya ketidakstasioneran yang memerlukan penanganan lebih lanjut (seperti *differencing*).

2.1.4. Transformasi Menuju Stasioneritas

Untuk mengubah data tidak stasioner menjadi stasioner, langkah yang paling umum digunakan adalah differencing (pembedaan):

- Differencing Tingkat Pertama (∇):
$$w_t = y_t - y_{t-1}$$

- Operasi ini berfungsi untuk menghilangkan tren linear dalam rata-rata. Setelah dilakukan *differencing*, variabel baru w_t akan memiliki mean nol dan struktur autokorelasi yang meluruh cepat (stasioner), yang kemudian valid untuk diidentifikasi orde p dan q -nya melalui plot ACF dan PACF.

2.2 Model Moving Average (MA(q))

Model *Moving Average* orde q dinotasikan sebagai MA(q) adalah model yang menyatakan bahwa nilai suatu deret waktu pada waktu t (y_t) merupakan kombinasi linier dari *error* acak (*white noise*) saat ini dan q periode sebelumnya.

2.2.1 Persamaan Dasar

Secara matematis, model MA(q) didefinisikan sebagai:

$$y_t = \mu + \epsilon_t - \theta_1 \epsilon_{t-1} - \dots - \theta_q \epsilon_{t-q}$$

Di mana:

8. μ adalah rata-rata proses.
9. ϵ_t adalah *white noise* dengan rata-rata 0 dan varians σ^2 .
10. $\theta_1, \dots, \theta_q$ adalah parameter model yang harus diestimasi.

2.2.2 Sifat Statistik Utama

7. Stasioneritas: Tidak seperti model AR, model MA(q) selalu stasioner untuk setiap nilai parameter θ yang terbatas, karena model ini merupakan kombinasi linier dari *white noise* yang memiliki varians konstan.
8. Ekspektasi (Mean): $E(y_t) = \mu$.
9. Varians: $\text{Var}(y_t) = \sigma^2(1 + \theta_1^2 + \dots + \theta_q^2)$.

2.2.3 Identifikasi Orde q (Plot ACF)

Ciri khas utama model MA(q) yang sangat membantu dalam analisis adalah perilaku fungsi autokorelasi (ACF)-nya:

- *Cut-off* (Terputus): Nilai autokorelasi ρ_k akan bernilai tepat nol untuk semua *lag* $k > q$.
- Dalam praktik nyata (data sampel), kita tidak akan mendapatkan angka nol yang sempurna, melainkan nilai yang sangat kecil. Untuk menguji signifikansinya, kita menggunakan batas interval kepercayaan:

$$\pm \frac{2}{\sqrt{N}}$$

Jika nilai autokorelasi sampel $r(k)$ berada di luar batas ini, maka lag tersebut dianggap signifikan.

Rumus Error Standar (Bartlett)

Untuk pengujian yang lebih akurat mengenai apakah autokorelasi tersebut signifikan, digunakan rumus *standard error* (s.e.) yang diajukan oleh Bartlett:

$$s.e.(r(k)) = N^{-1/2} \left(1 + 2 \sum_{j=1}^{k-1} r(j)^2 \right)^{1/2}$$

2.3 Model *Autoregressive* (AR(p))

Model *Autoregressive* orde p atau AR(p) merupakan metode pemodelan deret waktu di mana nilai variabel saat ini (y_t) dinyatakan sebagai fungsi linier dari nilai-nilai masa lalunya, ditambah dengan komponen *error* atau *disturbance* acak (*white noise*).

2.3.1 Persamaan Umum

Secara matematis, model AR(p) dirumuskan sebagai:

$$y_t = \delta + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \dots + \phi_p y_{t-p} + \epsilon_t$$

Atau menggunakan *backward shift operator* (B):

$$\Phi(B)y_t = \delta + \epsilon_t$$

di mana $\Phi(B) = 1 - \phi_1 B - \phi_2 B^2 - \dots - \phi_p B^p$.

2.3.2 Syarat Kausalitas dan Stasioneritas

Agar proses AR(p) bersifat stasioner, akar-akar dari polinomial karakteristik berikut harus berada di dalam lingkaran satuan (nilai mutlaknya kurang dari satu):

$$m^p - \phi_1 m^{p-1} - \phi_2 m^{p-2} - \dots - \phi_p = 0$$

Jika kondisi ini terpenuhi, proses AR(p) dapat dinyatakan sebagai representasi *Moving Average* yang konvergen (tak hingga):

$$y_t = \mu + \sum_{i=0}^{\infty} \psi_i \epsilon_{t-i}$$

Ini menunjukkan bahwa setiap *shock* acak di masa lalu memiliki kontribusi yang semakin mengecil seiring berjalannya waktu terhadap nilai saat ini.

Fungsi Autokorelasi (ACF) dan Persamaan Yule-Walker

Karakteristik penting dari model AR(p) adalah perilakunya terhadap autokorelasi. Autokorelasi untuk lag $k > 0$ memenuhi Persamaan Yule-Walker:

$$\rho(k) = \sum_{i=1}^p \phi_i \rho(k-i)$$

Persamaan ini merupakan *linear difference equations* yang menjelaskan bahwa pola ACF pada model AR tidak langsung terputus secara tajam, melainkan meluruh.

Berdasarkan akar-akar polinomial karakteristiknya, ACF dari proses AR(p) dapat berupa:

11. Peluruhan Eksponensial (*Exponential Decay*): Terjadi jika akar-akar polinomial bersifat nyata (*real*).
12. Peluruhan Sinusoidal Teredam (*Damped Sinusoid*): Terjadi jika terdapat akar kompleks, yang menghasilkan pola bergelombang yang perlahan meredam menuju nol.

2.4 Model *Mixed Autoregressive-Moving Average* (ARMA(p, q))

Model ARMA(p, q) merupakan penggabungan dari komponen *Autoregressive* (AR) dan *Moving Average* (MA). Pendekatan ini diambil ketika data deret waktu tidak cukup dimodelkan hanya dengan komponen AR atau MA saja, sehingga memerlukan kombinasi keduanya agar model menjadi lebih parsimoni (sederhana namun akurat).

2.4.1 Persamaan Umum

Model ARMA(p, q) dinyatakan sebagai:

$$y_t = \delta + \phi_1 y_{t-1} + \dots + \phi_p y_{t-p} + \epsilon_t - \theta_1 \epsilon_{t-1} - \dots - \theta_q \epsilon_{t-q}$$

Dalam bentuk ringkas menggunakan operator *backshift* (B):

$$\Phi(B)y_t = \delta + \Theta(B)\epsilon_t$$

di mana ϵ_t adalah proses *white noise*.

2.4.2 Kondisi Stasioneritas dan Invertibilitas

Sebuah model ARMA(p, q) harus memenuhi dua syarat utama agar layak digunakan:

13. Stasioneritas (Berkaitan dengan Komponen AR):

Model dikatakan stasioner jika akar-akar dari polinomial karakteristik AR:

$$m^p - \phi_1 m^{p-1} - \dots - \phi_p = 0$$

memiliki nilai mutlak kurang dari satu. Jika kondisi ini terpenuhi, ARMA dapat direpresentasikan sebagai model MA dengan bobot tak hingga (*infinite MA representation*).

14. Invertibilitas (Berkaitan dengan Komponen MA):

Model dikatakan *invertible* jika akar-akar dari polinomial karakteristik MA:

$$m^q - \theta_1 m^{q-1} - \dots - \theta_q = 0$$

memiliki nilai mutlak kurang dari satu. Syarat ini menjamin bahwa model dapat dinyatakan sebagai proses AR dengan bobot tak hingga (*infinite AR representation*), yang penting untuk estimasi parameter yang stabil.

2.4.3 Identifikasi Pola (ACF dan PACF)

Berbeda dengan model AR atau MA murni yang memiliki pola *cut-off* pada ACF atau PACF, model ARMA memiliki karakteristik yang lebih kompleks:

10. Pola Peluruhan: Baik ACF maupun PACF dari proses ARMA(p, q) umumnya menunjukkan pola peluruhan eksponensial (*exponential decay*) dan/atau peluruhan sinusoidal teredam (*damped sinusoid*).

11. Kesulitan Identifikasi: Karena tidak adanya *cut-off* yang tajam, penentuan orde p dan q secara visual melalui ACF/PACF menjadi lebih menantang. Oleh karena itu, praktisi sering menggunakan kriteria pemilihan model berbasis informasi seperti AIC (*Akaike Information Criterion*), AICC, atau BIC untuk membandingkan berbagai kombinasi orde (p, q) guna menemukan model terbaik.

2.5. Differencing (d)

Differencing (pembedaan) adalah salah satu teknik transformasi data yang paling sering digunakan untuk mengatasi ketidakstasioneran data runtun waktu, khususnya ketidakstasioneran yang disebabkan oleh adanya tren linear (rata-rata yang berubah seiring waktu).

2.5.1 Mekanisme Matematis

Secara matematis, proses *differencing* tingkat pertama ($d=1$) dilakukan dengan cara mengurangi nilai pengamatan pada suatu waktu tertentu (y_t) dengan nilai pengamatan pada satu periode sebelumnya (y_{t-1}). Operasi ini disimbolkan dengan operator diferensial (∇):

$$w_t = \nabla y_t = y_t - y_{t-1}$$

Jika dinyatakan dalam bentuk *backward shift operator* (B), di mana $By_t = y_{t-1}$, maka persamaannya menjadi:

$$w_t = (1 - B)y_t$$

2.5.2 Dampak Terhadap Data (Transformasi Menuju Stasioner)

Jika data awal (y_t) terbukti merupakan proses berjalan acak (*Random Walk*) yang mengandung tren linear atau *unit root* (akar unit) seperti pada persamaan berikut:

$$y_t = y_{t-1} + \epsilon_t$$

Maka melalui substitusi operasi *differencing* tingkat pertama, komponen tren akan tereliminasi secara otomatis sehingga menyisakan komponen kejut acak murni (*white noise*) yang stasioner:

$$w_t = (y_{t-1} + \epsilon_t) - y_{t-1} = \epsilon_t$$

Sebagai hasilnya, variabel baru w_t berubah menjadi deret waktu yang stasioner sempurna. Keberhasilan transformasi ini ditunjukkan secara visual melalui grafik Fungsi Autokorelasi (ACF) dan Fungsi Autokorelasi Parsial (PACF) dari data hasil pembedaan yang langsung terputus secara tajam (*cut off*) setelah lag nol, di mana seluruh batang koordinat lag berada di dalam batas interval kepercayaan signifikansi berikut:

$$\pm \frac{1.96}{\sqrt{N}}$$

Kondisi tersebut menandakan bahwa runtunan data baru w_t sudah tidak memiliki ketergantungan temporal masa lalu dan telah sukses diubah menjadi proses stasioner yang valid untuk tahapan identifikasi model runtun waktu selanjutnya.

2.6 Model ARIMA(p,d,q) dengan d=1

Model *Autoregressive Integrated Moving Average* atau ARIMA(p, d, q) merupakan model komprehensif yang memperluas kemampuan model ARMA untuk menangkap dinamika data runtun waktu yang pada awalnya tidak stasioner. Huruf I (*Integrated*) mencerminkan adanya proses pembedaan (*differencing*) untuk mencapai stasioneritas sebelum komponen AR(p) dan MA(q) diterapkan.

2.6.1 Formulasi Model ARIMA(p,1,q)

Ketika nilai parameter pembedaan ditetapkan sebesar $d=1$ model ini mengasumsikan bahwa data asli y_t tidak stasioner, tetapi data hasil pembedaan tingkat pertama ($w_t = \nabla y_t$) bersifat stasioner dan mengikuti proses gabungan ARMA(p,q).

Secara matematis, substitusi data stasioner w_t ke dalam struktur persamaan ARMA(p,q) menghasilkan rumusan sebagai berikut:

$$w_t = \delta + \phi_1 w_{t-1} + \dots + \phi_p w_{t-p} + \epsilon_t - \theta_1 \epsilon_{t-1} - \dots - \theta_q \epsilon_{t-q}$$

Jika dikembalikan ke dalam bentuk variabel asli y_t , persamaan di atas dijabarkan menjadi:

$$(y_t - y_{t-1}) = \delta + \phi_1 (y_{t-1} - y_{t-2}) + \dots + \phi_p (y_{t-p} - y_{t-p-1}) + \epsilon_t - \theta_1 \epsilon_{t-1} - \dots - \theta_q \epsilon_{t-q}$$

2.6.2 Representasi Operator Huruf Backshift

Menggunakan operator *backshift* (B), model ARIMA(p,1,q) dapat dituliskan secara lebih ringkas dan elegan sebagai:

$$\Phi(B)(1 - B)y_t = \delta + \Theta(B)\epsilon_t$$

Di mana:

15. $(1 - B)$ mewakili operasi *differencing* tingkat pertama ($d = 1$).
16. $\Phi(B) = 1 - \phi_1 B - \phi_2 B^2 - \dots - \phi_p B^p$ mewakili operator komponen *Autoregressive* (AR) berorde p.
17. $\Theta(B) = 1 - \theta_1 B - \theta_2 B^2 - \dots - \theta_q B^q$ mewakili operator komponen *Moving Average* (MA) berorde q.
18. ϵ_t adalah galat acak bernilai sisaan yang diasumsikan bersifat *white noise*.

Identifikasi Orde setelah $d=1$

Setelah data dipastikan stasioner melalui *differencing* satu kali ($d=1$), penentuan nilai orde p dan q didasarkan pada perilaku sisa ketergantungan linier pada data baru tersebut:

12. Orde AR (p) diidentifikasi dari jumlah lag pada plot PACF data stasioner yang keluar dari batas signifikansi sebelum mengalami *cut off*.
13. Orde MA (q) diidentifikasi dari jumlah lag pada plot ACF data stasioner yang keluar dari batas signifikansi sebelum mengalami *cut off*.
14. Jika kedua plot meluruh secara lambat (*tails off*), maka kombinasi model campuran seperti ARIMA(1,1,1) atau ARIMA(2,1,2) dipertimbangkan untuk diuji kelayakannya.

2.7 Diagnostik Model dan Pemilihan Model Terbaik

Setelah parameter dari berbagai kandidat model ARIMA(p,d,q) diestimasi menggunakan metode *Maximum Likelihood Estimation* (MLE), langkah krusial berikutnya adalah melakukan pengujian diagnostik (*diagnostic checking*) dan menerapkan kriteria seleksi untuk menentukan model yang paling valid dan efisien (parsimoni).

2.7.1. Diagnostik Residual (Sisaan)

Tujuan utama dari diagnostik model adalah untuk memastikan bahwa seluruh informasi sistematis dalam data telah ditangkap oleh model, sehingga yang tersisa hanyalah komponen acak murni atau sisaan (*residual*) yang ideal. Model dianggap memadai (*adequate*) jika residualnya memenuhi dua asumsi berikut:

A. Asumsi *White Noise* (Ketidakgantungan Residual)

Residual harus bersifat independen (tidak saling berkorelasi antar lag). Untuk mengujinya secara statistik, digunakan Uji Ljung-Box (Box-Pierce yang dimodifikasi). Uji ini memeriksa keberadaan autokorelasi secara simultan hingga lag ke- m .

Statistik uji Ljung-Box (Q) dirumuskan sebagai:

$$Q = N(N + 2) \sum_{k=1}^m \frac{\hat{\rho}_k^2}{N - k}$$

Di mana:

19. N adalah jumlah sampel/observasi setelah *differencing*.
20. $\hat{\rho}_k$ adalah nilai autokorelasi sampel dari residual pada lag ke- k .
21. m adalah jumlah lag maksimum yang diuji (dalam program Anda diatur lag=20).

Kriteria Keputusan:

15. Hipotesis Nol (H_0): Residual bersifat acak murni (*white noise* / tidak ada autokorelasi).
16. Jika nilai probabilitas (*p-value*) $> \alpha$ (biasanya 0.05), maka H_0 gagal ditolak, yang berarti model sukses menangkap seluruh ketergantungan temporal data dan layak digunakan untuk peramalan.

B. Asumsi Normalitas Residual

Selain harus *white noise*, residual idealnya berdistribusi normal dengan rata-rata nol dan varians konstan:

$$\epsilon_t \sim N(0, \sigma^2)$$

Dalam praktik riil, normalitas ini dievaluasi secara visual menggunakan Histogram Residual yang ditumpuk dengan Kurva Distribusi Normal Teoritis (seperti fungsi `curve(dnorm(...))` pada program R Anda). Jika bentuk histogram simetris menyerupai lonceng dan selaras dengan kurva normal, maka asumsi normalitas terpenuhi.

2.7.2. Kriteria Pemilihan Model Terbaik (AIC)

Sering kali terdapat lebih dari satu kandidat model ARIMA yang lolos uji diagnostik residual. Untuk menentukan satu model terbaik yang paling efisien, digunakan nilai AIC (*Akaike Information Criterion*). Secara matematis, AIC dihitung dengan rumus:

$$AIC = 2k - 2 \ln(L)$$

Di mana:

- k adalah jumlah parameter yang diestimasi dalam model (misal pada ARIMA(2,0,2), jumlah parameter $k = p + q + 1 = 5$).
- L adalah nilai maksimum dari fungsi *likelihood* model tersebut.

Prinsip Parsimoni (Keseimbangan Model):

Komponen $-2 \ln(L)$ mengukur seberapa baik model tersebut cocok dengan data (*goodness of fit*), sedangkan komponen $2k$ bertindak sebagai penalti terhadap jumlah parameter. Jika model terlalu kompleks (terlalu banyak parameter), nilai penalti $2k$ akan membesar secara drastis (*overfitting*). Oleh karena itu, model yang dipilih sebagai Model Terbaik adalah model kandidat yang menghasilkan nilai AIC terkecil. Model dengan AIC terkecil menjamin keakuratan peramalan yang tinggi namun dengan struktur model yang sesederhana mungkin.

Korelasi dengan Program R Anda:

- Langkah `Box.test(..., type="Ljung-Box")` dilakukan untuk menghitung statistik Q di atas.
- Langkah `AIC(model.ar1)`, `AIC(model.ma1)`, dst., digunakan untuk mengumpulkan nilai AIC dari ke-13 model kandidat yang Anda buat, sehingga Anda tinggal mencari nilai numerik terkecil di antara semuanya untuk menentukan `best.model`.

BAB III

METODOLOGI PENELITIAN

3.1 Metode Pengumpulan Data

Penelitian ini merupakan penelitian kuantitatif dengan pendekatan deskriptif analitis yang bertujuan untuk memodelkan pola dan fluktuasi volume lalu lintas kendaraan berdasarkan data deret waktu. Data yang digunakan merupakan data sekunder yang diperoleh melalui observasi terstruktur secara tidak langsung dengan memanfaatkan rekaman kamera Closed Circuit Television (CCTV) yang disediakan oleh Dinas Perhubungan Daerah Istimewa Yogyakarta (DIY) melalui portal CCTV Jogja Istimewa. Pengumpulan data dilakukan dengan cara mengamati rekaman CCTV pada Simpang Wardhani View Timur yang dapat diakses melalui situs CCTV Jogja Istimewa pada (<https://cctv.jogjaprov.go.id/>). Portal tersebut merupakan layanan pemantauan lalu lintas yang dikelola Pemerintah Daerah DIY dan terintegrasi dengan jaringan CCTV lalu lintas di berbagai titik wilayah Daerah Istimewa Yogyakarta.

Objek pengamatan dalam penelitian ini adalah kendaraan roda empat, meliputi mobil, truk, dan kendaraan sejenis, yang bergerak dari arah barat menuju timur pada Simpang Wardhani. Pencatatan volume kendaraan dilakukan secara manual oleh Kelompok 6 Kelas Analisis Runtun Waktu A. Pengamatan dilaksanakan secara konsisten setiap hari pada interval waktu yang sama, yaitu pukul 20.00 WIB hingga 20.03 WIB dengan durasi pengamatan selama tiga menit. Pengumpulan data dilakukan selama satu bulan, mulai tanggal 20 April sampai dengan 20 Mei, sehingga diperoleh sebanyak 31 observasi harian berupa jumlah kendaraan roda empat yang melintas pada periode pengamatan tersebut.

Data yang telah terkumpul kemudian dianalisis menggunakan metode Box–Jenkins melalui tahapan identifikasi model, estimasi parameter, pengujian diagnostik, dan peramalan untuk memperoleh model runtun waktu yang paling sesuai dalam menggambarkan pola volume lalu lintas kendaraan pada lokasi penelitian.

3.2 Pemeriksaan Kestasioneran Data Asli

Analisis runtun waktu pada penelitian ini diawali dengan menguji kestasioneran data volume lalu lintas kendaraan di Simpang Wardhani yang diperoleh dari rekaman CCTV View Timur. Langkah awal dilakukan dengan memeriksa perilaku data secara visual melalui pembuatan plot runtun waktu menggunakan fungsi `plot()`. Selanjutnya, struktur ketergantungan dan pola pergerakan linear dari data asli diidentifikasi secara statistik menggunakan fungsi autokorelasi `acf()` dan fungsi autokorelasi parsial `pacf()`. Apabila grafik fungsi autokorelasi meluruh menuju nilai nol secara cepat seiring bertambahnya lag waktu, data tersebut dinyatakan telah memenuhi kriteria stasioneritas dalam rata-rata sejak awal.

3.3 Model Moving Average Murni

Setelah perilaku data asli diamati, data diuji menggunakan pendekatan model *Moving Average* (MA) murni untuk melihat dampak dari guncangan acak masa lalu terhadap volume kendaraan saat ini. Model MA orde satu atau MA(1) dibentuk menggunakan fungsi `arima(cctv.ts, order=c(0, 0, 1))`, sedangkan model MA orde dua atau MA(2) dibentuk menggunakan fungsi `arima(cctv.ts, order=c(0, 0, 2))`. Identifikasi orde model ini didasarkan pada karakteristik grafik fungsi autokorelasi `acf()` yang terputus secara tajam (*cut-off*) setelah lag q . Bentuk persamaan formal untuk model MA(q) didefinisikan sebagai

berikut:

$$y_t = \mu + \epsilon_t - \theta_1 \epsilon_{t-1} - \theta_2 \epsilon_{t-2} - \dots - \theta_q \epsilon_{t-q}$$

Di mana μ mewakili rata-rata proses jangka panjang, ϵ_t adalah komponen kejut acak murni (*white noise*) pada saat t , dan $\theta_1, \dots, \theta_q$ merupakan parameter koefisien *moving average* yang harus diestimasi nilainya.

3.4 Model Autoregressive Murni

Tahapan analisis dilanjutkan dengan memetakan ketergantungan linear data berdasarkan nilai-nilai pengamatan masa lalunya sendiri melalui pendekatan model *Autoregressive* (AR) murni. Model AR orde satu atau AR(1) dibangun menggunakan fungsi `arima(cctv.ts, order=c(1, 0, 0))` dan model AR orde dua atau AR(2) dibangun menggunakan fungsi `arima(cctv.ts, order=c(2, 0, 0))`. Penentuan kesesuaian orde model AR didasarkan pada grafik fungsi autokorelasi parsial `pacf()` yang menunjukkan pola terputus secara tajam (*cut-off*) setelah lag p . Bentuk persamaan formal untuk model AR(p) dirumuskan sebagai berikut:

$$y_t = \delta + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \dots + \phi_p y_{t-p} + \epsilon_t$$

Di mana δ mewakili nilai konstanta intersep, $\phi_1, \dots, \phi_p$ menunjukkan parameter koefisien *autoregressive* yang mencerminkan besarnya pengaruh logis dari nilai lampau terhadap periode sekarang, dan ϵ_t menyatakan sisaan acak murni.

3.5 Transformasi Pembedaan Pertama

Meskipun hasil pemeriksaan awal melalui fungsi `acf()` dan `pacf()` mengindikasikan bahwa data asli cenderung berada dalam kondisi stasioner, prosedur formal pemodelan mewajibkan penerapan transformasi struktural untuk menjamin hilangnya unsur tren jangka panjang secara mutlak. Transformasi pembedaan tingkat pertama (*first-order differencing*) dengan nilai parameter $d=1$ diaplikasikan pada objek deret waktu menggunakan fungsi `diff()`. Operasi ini secara matematis mengurangi nilai pengamatan pada periode saat ini dengan nilai pengamatan satu periode sebelumnya untuk menghasilkan variabel baru w_t yang stasioner sempurna dalam rata-rata melalui persamaan sebagai berikut:

$$w_t = \nabla y_t = y_t - y_{t-1}$$

3.6. Model ARMA(p,q)

Model campuran *Autoregressive Moving Average* atau ARMA(p,q) dibentuk dengan mengombinasikan komponen parameter p dan q secara simultan tanpa melibatkan parameter integrasi diferensial di dalam fungsinya. Model campuran ini diestimasi menggunakan fungsi `arima()` dengan spesifikasi parameter `order=c(p, 0, q)`. Model ARMA digunakan ketika plot fungsi `acf()` and `pacf()` sama-sama menunjukkan pola meluruh secara lambat (*tails off*). Bentuk persamaan formal model ARMA(p,q) dinyatakan sebagai berikut:

$$y_t = \delta + \phi_1 y_{t-1} + \dots + \phi_p y_{t-p} + \epsilon_t - \theta_1 \epsilon_{t-1} - \dots - \theta_q \epsilon_{t-q}$$

3.7 Model ARIMA(p,d,q) dengan d=1

Ketika struktur model campuran ARMA(p,q) diterapkan secara langsung pada variabel data w_t yang telah melewati proses pembedaan tingkat pertama (d=1), maka model utuh tersebut didefinisikan sebagai model *Autoregressive Integrated Moving Average* atau ARIMA(p,1,q). Estimasi parameter model dilakukan menggunakan fungsi `arima()` dengan menentukan nilai komponen spesifikasi yaitu `order=c(p, 1, q)`. Bentuk persamaan formal model ARIMA(p,1,q) dirumuskan sebagai berikut:

$$w_t = \delta + \phi_1 w_{t-1} + \dots + \phi_p w_{t-p} + \epsilon_t - \theta_1 \epsilon_{t-1} - \dots - \theta_q \epsilon_{t-q}$$

3.8 Pemilihan Model Terbaik

Tahap akhir dari prosedur Box-Jenkins adalah menetapkan satu model paling optimal di antara ke-13 model kandidat yang telah diestimasi. Evaluasi kelayakan model dilakukan melalui uji diagnostik sisaan (*residual checking*) menggunakan fungsi `Box.test()` dengan spesifikasi `type="Ljung-Box"` untuk menguji sifat *white noise* melalui formulasi perhitungan statistik berikut:

$$Q = N(N + 2) \sum_{k=1}^m \frac{\hat{\rho}_k^2}{N - k}$$

Di mana N adalah jumlah sampel efektif, $\hat{\rho}_k$ adalah nilai autokorelasi sisaan pada lag ke- k , dan m melambangkan jumlah batas lag maksimum pengujian ($m=20$).

Untuk memverifikasi asumsi normalitas sisaan secara visual, digunakan fungsi `hist()` dan fungsi `curve(dnorm())`. Model yang ideal harus memiliki sisaan yang berdistribusi normal dengan rata-rata nol dan varians konstan yang diekspresikan sebagai:

$$\epsilon_t \sim N(0, \sigma^2)$$

Selanjutnya, pemilihan satu model terbaik dari seluruh kandidat model yang lolos uji diagnostik didasarkan pada nilai kriteria informasi terkecil yang dihitung menggunakan fungsi `AIC()`. Berdasarkan prinsip parsimoni, formula perhitungan nilai AIC didefinisikan sebagai berikut:

$$AIC = 2k - 2 \ln(L)$$

Di mana k menyatakan jumlah parameter yang diestimasi dalam struktur model dan L menyatakan nilai maksimal dari fungsi *likelihood*. Model dengan nilai numerik AIC terendah secara resmi ditetapkan sebagai model terbaik yang memiliki keseimbangan paling optimal antara akurasi kecocokan data dengan kesederhanaan struktur model untuk digunakan pada fungsi peramalan menggunakan fungsi `forecast()`.

BAB 4

HASIL DAN PEMBAHASAN


4.1 Deskripsi dan Karakteristik Visual Data

Analisis runtun waktu pada penelitian ini bertujuan untuk memodelkan fluktuasi harian volume lalu lintas kendaraan roda 4 yang berbelok ke arah kanan di Simpang Wardhani. Data diperoleh melalui metode observasi tidak langsung dari rekaman CCTV yang diakses melalui situs resmi Dinas Perhubungan Provinsi DIY (<https://cctv.jogjaproprov.go.id/>). Data yang dianalisis mencakup 31 observasi harian yang dicatat setiap pukul 20.00 hingga 20.03 WIB, terhitung sejak tanggal 20 April 2026 sampai dengan 20 Mei 2026.

Sebelum dilakukan pembentukan model, karakteristik dan pola pergerakan data asli dievaluasi terlebih dahulu secara visual melalui beberapa fungsi plot di RStudio untuk mendeteksi keberadaan unsur tren, keragaman varians, maupun kestasioneran data.

4.1.1 Plot Data Aktual Volume Kendaraan Harian

Identifikasi awal dilakukan dengan memetakan seluruh titik pengamatan data asli ke dalam grafik runtun waktu sebagai berikut:




Berdasarkan grafik runtun waktu yang dihasilkan oleh fungsi `plot(cctv.data[,2],type="o",pch=16,cex=.5,xlab="hari",ylab="Jumlah Kendaraan")`, terlihat bahwa volume harian kendaraan roda 4 yang berbelok ke kanan di Simpang Wardhani berfluktuasi secara dinamis dalam rentang antara 14 hingga 34 kendaraan per hari. Secara visual, pergerakan data dari hari ke-1 hingga hari ke-31 menunjukkan pola osilasi acak yang konstan di sekitar nilai tengahnya (rata-rata aktual sebesar 22.03 kendaraan).

Pola grafik tidak memperlihatkan adanya kecenderungan kemiringan struktural yang searah, baik berupa tren naik (*upward trend*) maupun tren turun (*downward trend*) jangka panjang yang persisten. Pola sebaran data yang konstan menembus garis rata-ratanya ini memberikan indikasi visual awal bahwa data riil hasil observasi Kelompok 6 telah berada dalam kondisi stasioner, baik secara rata-rata (*mean*) maupun secara varians.


4.1.2 Orde Orde Pembobotan SMA

Untuk meredam kejut acak (*irregular noise*) jangka pendek dan memperjelas arah pergerakan makro dari volume lalu lintas tersebut, diterapkan fungsi *Simple Moving Average* (SMA) dari paket TTR. Proses penghalusan pertama dilakukan dengan menentukan parameter rentang waktu jangka pendek ($n=3$) melalui fungsi `plot.ts(cctv.SMA3)`:



Grafik yang dieksekusi oleh fungsi `plot.ts(cctv.SMA3)` menghasilkan kurva pergerakan yang lebih halus (*smooth*) dibandingkan dengan grafik data aktualnya. Penggunaan orde pembobotan $n=3$ berhasil mengeliminasi riak-riak fluktuasi ekstrem antar-hari tanpa menghilangkan karakteristik lokal data. Kurva SMA 3 ini bergerak fluktuatif melintasi garis horizontal pusat secara stabil, yang memperkuat dugaan awal bahwa komponen rata-rata dari data volume lalu lintas ini tidak mengalami perubahan struktural seiring berjalannya waktu.

Selanjutnya, untuk melihat konsistensi pergerakan data dalam jangka menengah, rentang *window* penghalusan ditingkatkan dengan menetapkan nilai orde pembobotan $n=8$ melalui fungsi `plot.ts(cctv.SMA8)`




Grafik runtun waktu pasca-penerapan fungsi `plot.ts(cctv.SMA8)` menunjukkan efek peredaman galat acak yang jauh lebih kuat. Sebagian besar komponen fluktuasi harian telah melebur, menyisakan arah pergerakan tren makro data. Hasil visual dari kurva SMA 8 menunjukkan pergerakan garis yang cenderung mendatar dan stabil di sepanjang sumbu horizontal waktu. Tidak ditemukannya pergeseran tingkat tinggi-rendah data yang ekstrem pada kurva ini memberikan bukti visual yang semakin kuat dan solid bahwa data volume lalu lintas CCTV Simpang Wardhani tersebut telah stasioner.

4.1.3 Analisis Kestasioneran Berdasarkan Grafik (ACF dan PACF)

Untuk memverifikasi asumsi stasioneritas secara statistik dan menentukan langkah pemodelan Box-Jenkins selanjutnya, dilakukan analisis visual melalui grafik korelogram menggunakan fungsi `acf()` dan `pacf()`. Evaluasi struktur autokorelasi pada data asli dijalankan melalui perintah

```
acf(cctv.ts, main="ACF Sebelum differencing")
pacf(cctv.ts, main="PACF Sebelum differencing")
```



Grafik ACF yang dihasilkan menunjukkan bahwa koefisien autokorelasi tidak meluruh secara instan atau tajam menuju nol (*die out rapidly*). Dalam proses deret waktu yang stasioner, koefisien autokorelasi seharusnya meluruh secara geometris atau terputus secara cepat ke dalam interval kepercayaan. Sebaliknya, pada data ini, terlihat adanya pola ketergantungan yang persistens di mana koefisien autokorelasi pada *lag* ke-2 dan ke-6 melampaui batas signifikansi (garis putus-putus biru). Kondisi tersebut diperkuat oleh grafik PACF yang menunjukkan fluktuasi signifikan dan tidak stabil. Terdapat *spike* yang melewati batas signifikansi pada *lag* ke-2 dan *lag* ke-6. Dalam konteks pemodelan deret waktu, pola ini menunjukkan bahwa data tidak hanya dipengaruhi oleh satu periode sebelumnya, tetapi memiliki struktur ketergantungan historis yang cukup kompleks. Secara teoretis, kombinasi antara ACF yang meluruh perlahan dan PACF yang menunjukkan fluktuasi signifikan pada *lag* jauh merupakan indikator kuat bahwa data memiliki *memory* yang panjang dan tidak stasioner dalam rata-rata, yang sering

kali menjadi pertanda adanya *unit root* dalam proses stokastik tersebut.


4.1.4 Evaluasi Stasioneritas Setelah Transformasi *Differencing*

Untuk menangani ketidakstasioneran yang ditemukan pada data asli, dilakukan transformasi *differencing* tingkat pertama dengan parameter $d=1$ menggunakan fungsi `diff()` pada objek deret waktu.


Transformasi ini bertujuan untuk menghilangkan komponen tren dengan menghitung selisih antara nilai pada observasi saat ini (Y_t) dan observasi sebelumnya (Y_{t-1}), yang secara matematis dirumuskan sebagai $w_t = Y_t - Y_{t-1}$.

Implementasi transformasi tersebut dilakukan dengan perintah: `wt.cctv <- diff(cctv.ts, differences=1)`

`plot.ts(wt.cctv)`



Setelah dilakukan transformasi, plot deret waktu menunjukkan pola fluktuasi yang lebih stabil di sekitar nilai tengah nol dibandingkan dengan data asli. Untuk memastikan kestasioneran secara visual dan mengidentifikasi orde model ARIMA, dilakukan analisis kembali pada grafik ACF dan PACF menggunakan fungsi `acf()` dan `pacf()` :



Berdasarkan hasil visualisasi ACF dan PACF dari data hasil *differencing* tersebut, terlihat bahwa koefisien autokorelasi meluruh menuju nol dengan jauh lebih cepat dibandingkan dengan data asli. Sebagian besar *spike* pada grafik telah masuk ke dalam batas interval kepercayaan (garis putus-putus biru). Pola ini mengindikasikan bahwa deret waktu telah mencapai kondisi stasioner dan memenuhi asumsi dasar untuk melanjutkan ke tahap identifikasi orde model AR (p) dan MA (q).


4.2 Estimasi Parameter dan Diagnostik

4.2.1 Model Moving Average Orde Satu (MA(1))

Model murni pertama yang diestimasi adalah model MA(1). Melalui pengekseskuan fungsi `arima(wt.cctv, order=c(0, 0, 1))`, diperoleh nilai koefisien komponen `ma1` sebesar -1.0000 dengan galat baku (standard error) sebesar 0.0933, serta nilai konstanta intercept sebesar -0.1645. Struktur model ini menghasilkan nilai taksiran varians $\sigma^2 = 25.5$, nilai log likelihood sebesar -92.86, dan kriteria informasi AIC = 191.73. Bentuk persamaan formal model MA(1) untuk data volume kendaraan ini dirumuskan sebagai berikut:

$$y_t = -0.1645 + \epsilon_t - 1.0000\epsilon_{t-1}$$


Setelah parameter model didapatkan, dilakukan pengujian diagnostik untuk memeriksa apakah komponen sisaan (residual) telah bebas dari korelasi linear dan berdistribusi normal menggunakan fungsi `acf()` dan `pacf()`.



Grafik ACF dan PACF dari sisaan model menunjukkan bahwa seluruh batang koefisien autokorelasi dan autokorelasi parsial dari *lag* 1 hingga 20 berada sepenuhnya di dalam rentang batas selang kepercayaan. Secara teoretis, sisaan yang ideal bagi sebuah model deret waktu adalah yang tidak memiliki struktur ketergantungan pada *lag* berapapun. Konsistensi hasil antara kedua grafik ini, di mana tidak ditemukan *spike* yang signifikan, menunjukkan secara visual bahwa sisaan model MA(1) tidak memiliki korelasi linear antar-waktu.

langkah pengujian diagnostik dilanjutkan dengan memeriksa asumsi normalitas sisaan melalui visualisasi histogram, yang kemudian ditumpuk dengan kurva distribusi normal teoritis menggunakan perintah `curve(dnorm(...))`. Visualisasi ini bertujuan untuk mengamati kesesuaian sebaran empiris galat terhadap asumsi sebaran normal yang mendasari inferensi statistik model.


Histogram of model.ma1\$residuals



Plot histogram sisaan model MA(1) yang dilengkapi dengan kurva distribusi normal teoritis (garis putus-putus merah) menunjukkan sebaran kepadatan (*density*) galat sampel. Secara visual, bentuk histogram cenderung simetris dan berpusat di sekitar nilai nol. Meskipun terdapat lonjakan frekuensi yang cukup tinggi tepat di nilai tengah (nol) serta sedikit kebaikan pencilan di ekor kanan, polanya secara umum masih mendekati bentuk lonceng (*bell-shaped*). Hal ini mengindikasikan bahwa asumsi normalitas sisaan terpenuhi secara visual. Karakteristik sisaan ini diperkuat secara statistik melalui output fungsi `Box.test()` dengan spesifikasi `type="Ljung-Box"` yang menghasilkan nilai statistik $\chi^2 = 32.655$ dengan derajat bebas $df = 19$ dan nilai probabilitas $p\text{-value} = 0.02634$. Karena $p\text{-value} < 0.05$, maka hipotesis nol ditolak, yang berarti sisaan model MA(1) belum dinyatakan sebagai acak murni (white noise).


4.2.2 Model Moving Average Orde Dua (MA(2))

Model murni berikutnya yang diuji adalah model MA(2) melalui pemanggilan fungsi `arima(wt.cctv, order=c(0, 0, 2))`. Hasil estimasi memberikan nilai koefisien `ma1` sebesar -1.2015, koefisien `ma2` sebesar 0.2015, dan nilai intercept sebesar -0.1589. Model ini menghasilkan estimasi varians sisaan $\sigma^2 = 23.59$, nilai log likelihood sebesar -91.93, serta nilai kriteria informasi AIC = 191.87. Bentuk persamaan formal untuk model MA(2) didefinisikan sebagai berikut: $y_t = -0.1589 + \epsilon_t - 1.2015\epsilon_{t-1} + 0.2015\epsilon_{t-2}$. Setelah parameter model didapatkan, dilakukan pengujian diagnostik untuk memeriksa apakah komponen sisaan (residual) telah bebas dari korelasi linear dan berdistribusi normal men



Grafik ACF dan PACF dari sisaan model menunjukkan bahwa seluruh batang koefisien autokorelasi dan autokorelasi parsial dari *lag* 1 hingga 20 berada sepenuhnya di dalam rentang batas selang kepercayaan (garis putus-putus biru). Secara teoretis, sisaan yang ideal bagi sebuah model deret waktu adalah yang tidak memiliki struktur ketergantungan pada *lag* berapapun. Konsistensi hasil antara kedua grafik ini, di mana tidak ditemukan *spike* yang signifikan, menunjukkan secara visual bahwa sisaan model MA(2) tidak memiliki korelasi linear antar-waktu

langkah pengujian diagnostik dilanjutkan dengan memeriksa asumsi normalitas sisaan melalui visualisasi histogram, yang kemudian ditumpuk dengan kurva distribusi normal teoritis menggunakan perintah `curve(dnorm(...))`. Visualisasi ini bertujuan untuk mengamati kesesuaian sebaran empiris galat terhadap asumsi sebaran normal yang mendasari inferensi statistik model.



Visualisasi grafik histogram gabungan pada model MA(2) menunjukkan sebaran data sisaan yang mengelompok secara proporsional di sekitar nilai rata-rata nol dan tertutup dengan baik oleh kurva


densitas normal teoritis. Sifat independensi galat ini dikonfirmasi secara matematis oleh hasil uji Ljung-Box yang menunjukkan nilai statistik $\chi^2 = 29.101$ dengan derajat bebas $df = 18$ dan nilai probabilitas $p\text{-value} = 0.04716$. Karena $p\text{-value} < 0.05$, maka hipotesis nol ditolak, yang berarti sisaan model MA(2) belum dinyatakan sebagai acak murni (white noise).

4.2.3 Model Autoregressive Orde Satu (AR(1))

Pemodelan murni dialihkan pada komponen ketergantungan nilai masa lalu menggunakan fungsi `arima(cctv.ts, order=c(1, 0, 0))`. Proses estimasi parameter menghasilkan koefisien $ar1$ sebesar -0.7620 dengan galat baku (standard error) sebesar 0.1095 , serta nilai konstanta intercept sebesar -0.2495 . Struktur model ini menghasilkan nilai taksiran varians $\sigma^2 = 26.53$, $\log \text{likelihood} = -92.18$, dan nilai $AIC = 190.35$. Persamaan formal model AR(1) untuk data volume kendaraan ini dirumuskan sebagai berikut:

$$y_t - (-0.2495) = -0.7620(y_{t-1} - (-0.2495)) + \epsilon_t$$


Untuk menguji apakah model AR(1) telah sukses menyerap seluruh informasi linear data harian, grafik ACF sisaan dieksekusi menggunakan fungsi berikut:



Grafik ACF dan PACF dari sisaan model menunjukkan bahwa seluruh batang koefisien autokorelasi dan autokorelasi parsial dari *lag* 1 hingga 20 berada sepenuhnya di dalam rentang batas selang kepercayaan (garis putus-putus biru). Secara teoretis, sisaan yang ideal bagi sebuah model deret waktu adalah yang tidak memiliki struktur ketergantungan pada *lag* berapapun. Konsistensi hasil antara kedua grafik ini, di mana tidak ditemukan *spike* yang signifikan, menunjukkan secara visual bahwa sisaan model AR(1) tidak memiliki korelasi linear antar-waktu.

Langkah pengujian diagnostik dilanjutkan dengan memeriksa asumsi normalitas sisaan melalui visualisasi histogram, yang kemudian ditumpuk dengan kurva distribusi normal teoritis menggunakan perintah `curve(dnorm(...))`. Visualisasi ini bertujuan untuk mengamati kesesuaian sebaran empiris galat terhadap asumsi sebaran normal yang mendasari inferensi statistik model.

Histogram of model.ar1\$residuals




Tampilan visual histogram frekuensi residual model AR(1) memperlihatkan struktur sebaran yang simetris dan mengikuti profil kurva normal berwarna merah secara ideal. Berdasarkan hasil uji Ljung-Box, diperoleh nilai statistik $\chi^2 = 26$ dengan derajat bebas $df = 19$ dan nilai $p\text{-value} = 0.1302$. Karena $p\text{-value} > 0.05$, model AR(1) dinyatakan lolos uji diagnostik karena sisaannya telah bersifat acak murni (*white noise*).

4.2.4 Model Autoregressive Orde Dua (AR(2))

Model murni terakhir pada tahap ini adalah model AR(2) yang dieksekusi menggunakan fungsi `arima(cctv.ts, order=c(2, 0, 0))`. Nilai koefisien parameter yang diperoleh adalah $ar1$ sebesar -0.8814, koefisien $ar2$ sebesar -0.1500, dan nilai intercept sebesar -0.2417. Model ini menghasilkan estimasi varians sisaan $\sigma^2 = 25.86$, nilai log likelihood sebesar -91.82, serta nilai kriteria informasi AIC = 191.64. Bentuk persamaan formal untuk model AR(2) didefinisikan sebagai berikut:


$$y_t = -0.2417 + \epsilon_t - 0.8814y_{t-1} - 0.1500y_{t-2}$$

Pengujian diagnostik sisaan untuk model AR(2) diawali dengan menampilkan grafik korelogram melalui fungsi berikut:



Grafik ACF dan PACF dari sisaan model menunjukkan bahwa seluruh batang koefisien autokorelasi dan autokorelasi parsial dari *lag* 1 hingga 20 berada sepenuhnya di dalam rentang batas selang kepercayaan (garis putus-putus biru). Secara teoretis, sisaan yang ideal bagi sebuah model deret waktu adalah yang tidak memiliki struktur ketergantungan pada *lag* berapapun. Konsistensi hasil antara kedua grafik ini, di mana tidak ditemukan *spike* yang signifikan, menunjukkan secara visual bahwa sisaan model AR(1) tidak memiliki korelasi linear antar-waktu

Langkah pengujian diagnostik dilanjutkan dengan memeriksa asumsi normalitas sisaan melalui visualisasi histogram, yang kemudian ditumpuk dengan kurva distribusi normal teoritis menggunakan perintah `curve(dnorm(...))`. Visualisasi ini bertujuan untuk mengamati kesesuaian sebaran empiris galat terhadap asumsi sebaran normal yang mendasari inferensi statistik model.



Visualisasi grafik histogram dan kurva densitas normal teoritis pada sisaan AR(2) memperlihatkan tingkat keselarasan bentuk yang sangat baik, di mana sebaran data memusat secara seimbang di sekitar titik rata-rata nol. Karakteristik ini didukung secara matematis oleh luaran uji Ljung-Box yang menghasilkan nilai statistik $\chi^2 = 24.794$ dengan derajat bebas $df = 18$ serta capaian nilai $p\text{-value} = 0.1307$. Nilai probabilitas yang lebih besar dari 0.05 ini menegaskan bahwa model AR(2) memadai secara statistik dan sisaannya memenuhi asumsi *white noise*.

4.3 Estimasi Parameter dan Diagnostik Model Campuran ARMA(p,q)


Pengujian dilanjutkan dengan menggunakan model campuran *Autoregressive Moving Average* atau ARMA(p,q). Model campuran ini digunakan untuk menangkap struktur ketergantungan data yang lebih kompleks, di mana nilai volume lalu lintas kendaraan diasumsikan dipengaruhi oleh kombinasi linear nilai masa lalunya (komponen AR) sekaligus kontribusi dari guncangan sisaan acak masa lalunya (komponen MA).

4.3.1 Model ARMA(1,1)

Berdasarkan hasil estimasi parameter menggunakan fungsi `arima(wt.cctv, order=c(1, 0, 1))` menghasilkan nilai koefisien parameter `ar1` sebesar -0.3256 dan koefisien parameter `ma1` sebesar -1.0000, dengan nilai konstanta `intercept` sebesar -0.1579. Struktur model ini menghasilkan nilai taksiran varians $\sigma^2 = 22.39$, $\log \text{likelihood} = -91.24$, dan nilai $\text{AIC} = 190.48$. Persamaan formal model ARMA(1,1) dirumuskan sebagai berikut:

$$y_t = -0.1579 + \epsilon_t - 0.3256y_{t-1} - 1.0000\epsilon_{t-1}$$


Evaluasi terhadap kelayakan model ini dilakukan melalui serangkaian plot diagnostik galat sebagai berikut:



Grafik Fungsi Autokorelasi (ACF) dan Fungsi Autokorelasi Parsial (PACF) dari sisaan model ARMA(1,1) digunakan untuk memeriksa apakah masih terdapat ketergantungan linear antar-waktu yang tertinggal pada komponen galat. Berdasarkan plot yang dihasilkan:

Terlihat bahwa seluruh batang koefisien autokorelasi (ACF) maupun autokorelasi parsial (PACF) dari *lag* 1 hingga 20 berada sepenuhnya di dalam rentang interval kepercayaan statistik (garis putus-putus berwarna biru). Secara teoretis, sisaan yang ideal bagi sebuah model deret waktu adalah yang tidak memiliki struktur ketergantungan pada *lag* berapapun. Konsistensi hasil antara kedua grafik ini, di mana tidak ditemukan *spike* yang signifikan melampaui batas kritis $\pm 2/\sqrt{N}$, menunjukkan secara visual bahwa sisaan model ARMA(1,1) tidak memiliki korelasi linear antar-waktu. Tidak adanya lonjakan batang yang menembus batas signifikansi tersebut menandakan bahwa tidak ada informasi temporal residual yang terlewatkan oleh struktur model ARMA(1,1), sehingga model telah berhasil mengekstraksi seluruh informasi sistematis yang terkandung dalam data dan sisaan dinyatakan telah bersifat acak murni (*white noise*)

Histogram of model.arma11\$residual



Visualisasi kurva distribusi normal teoretis berwarna merah (*dnorm*) ditumpangkan secara langsung di atas struktur histogram frekuensi sisaan model ARMA(1,1). Secara visual, sebaran histogram sampel menunjukkan profil yang cenderung simetris di sekitar nilai rata-rata nol. Meskipun terdapat sedikit deviasi lokal antara tinggi batang histogram dengan kurva normal teoretis, pola tersebut secara umum telah merepresentasikan asumsi distribusi normal yang mendasari inferensi statistik model.

Karakteristik sisaan ini diperkuat melalui pengujian formal independensi galat menggunakan fungsi `Box.test()` dengan spesifikasi `type="Ljung-Box"`. Hasil pengujian menghasilkan nilai statistik dengan $\chi^2 = 30.112$ dengan derajat bebas $df = 18$ dan nilai $p\text{-value} = 0.03637$. Karena $p\text{-value} < 0.05$, maka hipotesis nol ditolak, yang berarti sisaan model ARMA(1,1) belum dinyatakan sebagai acak murni (*white noise*). Sehingga model ini dinyatakan sebagai kandidat yang paling valid dan kuat secara statistik untuk digunakan dalam proses peramalan.


4.3.2 Model ARMA(1,2)

Estimasi parameter model campuran melalui fungsi `arima(wt.cctv, order=c(1, 0, 2))` menghasilkan nilai

koefisien ar1 sebesar -0.7242, koefisien ma1 sebesar -0.5778, dan koefisien ma2 sebesar -0.4214, dengan nilai intercept sebesar -0.1597. Struktur model ini menghasilkan nilai taksiran varians $\sigma^2 = 20.89$, log likelihood = -90.16, dan nilai AIC = 190.32. Persamaan formal model ARMA(1,2) dirumuskan sebagai berikut:

$$y_t = -0.1597 + \epsilon_t - 0.7242y_{t-1} - 0.5778\epsilon_{t-1} - 0.4214\epsilon_{t-2} .$$


Evaluasi kelayakan sisaan dianalisis melalui plot berikut:



Grafik Fungsi Autokorelasi (ACF) dan Fungsi Autokorelasi Parsial (PACF) dari sisaan model ARMA(1,2) digunakan untuk memeriksa apakah masih terdapat ketergantungan linear antar-waktu yang tertinggal pada komponen galat. Berdasarkan plot yang dihasilkan:

Terlihat bahwa seluruh batang koefisien autokorelasi (ACF) maupun autokorelasi parsial (PACF) dari *lag* 1 hingga 20 berada sepenuhnya di dalam rentang interval kepercayaan statistik (garis putus-putus berwarna biru). Secara teoretis, sisaan yang ideal bagi sebuah model deret waktu adalah yang tidak memiliki struktur ketergantungan pada *lag* berapapun. Konsistensi hasil antara kedua grafik ini, di mana tidak ditemukan *spike* yang signifikan melampaui batas kritis $\pm 2/\sqrt{N}$, menunjukkan secara visual bahwa sisaan model ARMA(1,2) tidak memiliki korelasi linear antar-waktu. Tidak adanya lonjakan batang yang menembus batas signifikansi tersebut menandakan bahwa tidak ada informasi temporal residual yang terlewatkan oleh struktur model ARMA(1,2), sehingga model telah berhasil mengekstraksi seluruh informasi sistematis yang terkandung dalam data dan sisaan dinyatakan telah bersifat acak murni (*white noise*)

Histogram of model.arma12\$residual



Visualisasi kurva densitas normal teoretis (*dnorm*) menunjukkan tingkat kelekatan (*goodness-of-fit*) yang cukup presisi di atas sebaran histogram frekuensi sisaan model ARMA(1,2). Struktur histogram sampel menunjukkan profil sebaran yang cenderung simetris dan seimbang di sekitar nilai rata-rata nol, yang mengindikasikan bahwa asumsi normalitas sisaan telah terpenuhi dengan baik.

Karakteristik sisaan ini diperkuat secara statistik melalui pengujian independensi sisaan menggunakan fungsi `Box.test()` dengan spesifikasi `type="Ljung-Box"`. Hasil pengujian menghasilkan nilai statistik $\chi^2 = 29.202$ dengan derajat bebas $df = 17$ dan nilai $p\text{-value} = 0.03271$. Karena $p\text{-value} < 0.05$, maka hipotesis nol ditolak, yang berarti sisaan model ARMA(1,2) belum dinyatakan sebagai acak murni (white noise)., yang mengonfirmasi bahwa model tersebut layak secara statistik dan memadai untuk digunakan dalam proses peramalan.


4.3.3 Model ARMA(2,1)

Melalui penambahan orde autoregressive, fungsi `arima(wt.cctv, order=c(2, 0, 1))` menghasilkan nilai koefisien $ar1$ sebesar -0.1861, $ar2$ sebesar 0.3562, dan koefisien $ma1$ sebesar -1.0000, dengan nilai intercept sebesar -0.1711. Struktur model ini menghasilkan nilai taksiran varians $\sigma^2 = 20.08$, log likelihood = -89.29, dan nilai AIC = 188.59. Persamaan formal model ARMA(2,1) dirumuskan sebagai berikut:


$$y_t = -0.1711 + \epsilon_t - 0.1861y_{t-1} + 0.3562y_{t-2} - 1.0000\epsilon_{t-1}$$

Evaluasi terhadap sisaan model ini dipetakan melalui visualisasi plot berikut:

Histogram of model.arma21\$residual




Series model.arma22\$residuals



Grafik Fungsi Autokorelasi (ACF) dan Fungsi Autokorelasi Parsial (PACF) dari sisaan model ARMA(2,1) digunakan untuk memeriksa apakah masih terdapat ketergantungan linear antar-waktu yang tertinggal pada komponen galat. Berdasarkan plot yang dihasilkan:

Terlihat bahwa seluruh batang koefisien autokorelasi (ACF) maupun autokorelasi parsial (PACF) dari *lag* 1 hingga 20 berada sepenuhnya di dalam rentang interval kepercayaan statistik (garis putus-putus berwarna biru). Secara teoretis, sisaan yang ideal bagi sebuah model deret waktu adalah yang tidak memiliki struktur ketergantungan pada *lag* berapapun. Konsistensi hasil antara kedua grafik ini, di mana tidak ditemukan *spike* yang signifikan melampaui batas kritis $\pm 2/\sqrt{N}$, menunjukkan secara visual bahwa sisaan model ARMA(2,1) tidak memiliki korelasi linear antar-waktu. Tidak adanya lonjakan batang yang menembus batas signifikansi tersebut menandakan bahwa tidak ada informasi temporal residual yang terlewatkan oleh struktur model ARMA(2,1), sehingga model telah berhasil mengekstraksi seluruh informasi sistematis yang terkandung dalam data dan sisaan dinyatakan telah bersifat acak murni (*white noise*)

Histogram of model.arma21\$residual



Visualisasi kurva densitas normal teoretis (*dnorm*) yang ditumpangkan di atas struktur histogram frekuensi sisaan model ARMA(2,1) memperlihatkan pola sebaran yang memusat di sekitar nilai rata-rata nol dengan profil simetris. Kecenderungan pola tersebut memberikan indikasi empiris bahwa sisaan model telah memenuhi asumsi normalitas yang disyaratkan dalam pemodelan deret waktu.


Karakteristik sisaan ini diperkuat secara statistik melalui pengujian independensi galat menggunakan fungsi `Box.test()` dengan spesifikasi `type="Ljung-Box"`. Hasil pengujian menghasilkan nilai statistik $\chi^2 = 25.197$ dengan derajat bebas $df = 17$ dan nilai $p\text{-value} = 0.09039$. Karena $p\text{-value} > 0.05$, maka hipotesis nol gagal ditolak, yang berarti sisaan model ARMA(2,1) dinyatakan telah bersifat acak murni (white noise), yang mengonfirmasi bahwa model telah valid secara statistik untuk digunakan dalam peramalan.

4.3.4 Model ARMA(2,2)

Estimasi parameter pada model campuran orde tertinggi tanpa pembedaan dijalankan melalui fungsi menggunakan fungsi `arima(wt.cctv, order=c(2, 0, 2))` menghasilkan nilai koefisien ar_1 sebesar -0.2851, ar_2 sebesar 0.3266, koefisien ma_1 sebesar -0.8886, dan koefisien ma_2 sebesar -0.1114, dengan nilai intercept sebesar -0.1695. Struktur model ini menghasilkan nilai taksiran varians $\sigma^2 = 19.95$, log likelihood = -89.23, dan nilai AIC = 190.47. Persamaan formal model ARMA(2,2) dirumuskan sebagai berikut:

$$y_t = -0.1695 + \epsilon_t - 0.2851y_{t-1} + 0.3266y_{t-2} - 0.8886\epsilon_{t-1} - 0.1114\epsilon_{t-2}$$


Pengujian kualitas sisaan model dianalisis melalui plot sebagai berikut:



Grafik Fungsi Autokorelasi (ACF) dan Fungsi Autokorelasi Parsial (PACF) dari sisaan model ARMA(2,2) digunakan untuk memeriksa apakah masih terdapat ketergantungan linear antar-waktu yang tertinggal pada komponen galat. Berdasarkan plot yang dihasilkan:

Terlihat bahwa seluruh batang koefisien autokorelasi (ACF) maupun autokorelasi parsial (PACF) dari *lag* 1 hingga 20 berada sepenuhnya di dalam rentang interval kepercayaan statistik (garis putus-putus berwarna biru). Secara teoretis, sisaan yang ideal bagi sebuah model deret waktu adalah yang tidak

memiliki struktur ketergantungan pada *lag* berapapun. Konsistensi hasil antara kedua grafik ini, di mana tidak ditemukan *spike* yang signifikan melampaui batas kritis $\pm 2/\sqrt{N}$, menunjukkan secara visual bahwa sisaan model ARMA(2,2) tidak memiliki korelasi linear antar-waktu. Tidak adanya lonjakan batang yang menembus batas signifikansi tersebut menandakan bahwa tidak ada informasi temporal residual yang terlewatkan oleh struktur model ARMA(2,2), sehingga model telah berhasil mengekstraksi seluruh informasi sistematis yang terkandung dalam data dan sisaan dinyatakan telah bersifat acak murni (*white noise*)




Visualisasi kurva densitas normal teoretis (*dnorm*) menunjukkan tingkat kelekatan (*goodness-of-fit*) yang cukup presisi di atas sebaran histogram frekuensi sisaan model ARMA(2,2). Struktur histogram sampel memperlihatkan profil sebaran yang cenderung simetris dan seimbang di sekitar nilai rata-rata nol, yang mengindikasikan bahwa asumsi normalitas sisaan telah terpenuhi dengan baik.

Karakteristik sisaan ini diperkuat secara statistik melalui pengujian independensi galat menggunakan fungsi `Box.test()` dengan spesifikasi `type="Ljung-Box"`. Hasil pengujian menghasilkan nilai statistik $\chi^2 = 25.436$ dengan derajat bebas $df = 16$ dan nilai $p\text{-value} = 0.0625$. Karena $p\text{-value} > 0.05$, maka hipotesis nol gagal ditolak, yang berarti sisaan model ARMA(2,2) dinyatakan telah bersifat acak murni (*white noise*), sehingga model ini dinyatakan sebagai kandidat yang paling valid dan kuat secara statistik untuk digunakan dalam proses peramalan.


4.4 penerapan Model ARIMA dengan $d=1$

4.4.1 Model ARIMA(0,1,1)

Estimasi parameter untuk model ARIMA paling mendasar dengan proses pembedaan satu kali dijalankan menggunakan `arima(wt.cctv, order=c(0, 1, 1))`. Proses komputasi menghasilkan nilai koefisien parameter μ_1 sebesar -1.0000 dengan taksiran nilai varians sisaan (σ^2) sebesar 69.67. Nilai fungsi kebolehjadian dicatat sebesar $\log \text{likelihood} = -104.38$ dengan nilai kriteria informasi $AIC = 212.77$. Rumusan persamaan formal model ARIMA(0,1,1) didefinisikan sebagai berikut: $(y_t - y_{t-1}) = \epsilon_t - 1.0000\epsilon_{t-1}$. Evaluasi kelayakan mekanis sisaan model ARIMA(0,1,1) diperiksa melalui plot berikut:



Analisis visual gabungan terhadap grafik korelogram ACF dan PACF dari sisaan model ARIMA(0,1,1) dilakukan untuk memeriksa sisa dependensi linier galat. Berdasarkan grafik ACF, sebagian besar koefisien korelasi lag sisaan terkendali di bawah garis putus-putus biru. Namun pada grafik PACF, terdapat indikasi fluktuasi minor pada beberapa lag awal yang mendekati batas kritis signifikansi, yang menandakan diperlukannya pengujian hipotesis formal secara statistik.



Visualisasi kurva densitas normal teoretis (dnorm) menunjukkan tingkat kelekatan (*goodness-of-fit*) yang cukup presisi di atas sebaran histogram frekuensi sisaan model ARIMA(0,1,1). Struktur histogram sampel memperlihatkan profil sebaran yang cenderung simetris dan seimbang di sekitar nilai rata-rata nol, yang mengindikasikan bahwa asumsi normalitas sisaan telah terpenuhi dengan baik.

Karakteristik sisaan ini diperkuat secara statistik melalui pengujian independensi galat menggunakan fungsi `Box.test()` dengan spesifikasi `type="Ljung-Box"`. Hasil pengujian menghasilkan nilai statistik $\chi^2 = 62.203$ dengan derajat bebas $df = 19$ dan nilai $p\text{-value} = 1.726 \times 10^{-6}$. Mengingat nilai $p\text{-value} < 0.05$, maka hipotesis nol ditolak. Hal ini menunjukkan bahwa sisaan model ARIMA(0,1,1)


masih mengandung autokorelasi, sehingga model ini dinyatakan tidak layak

4.4.2 Model ARIMA(1,1,1)

Estimasi parameter melalui fungsi `arima(wt.cctv, order=c(1, 1, 1))` menghasilkan nilai koefisien ar1 sebesar -0.7543 dan koefisien ma1 sebesar -1.0000 , dengan nilai taksiran $\sigma^2 = 27.48$ serta nilai $\text{AIC} = 189.72$. Persamaan matematika formal untuk model ARIMA(1,1,1) dirumuskan sebagai berikut:


$$(y_t - y_{t-1}) = -0.7543(y_{t-1} - y_{t-2}) + \epsilon_t - 1.0000\epsilon_{t-1}$$

Evaluasi kelayakan sisaan model campuran ini dianalisis melalui visualisasi fungsi plot berikut:



Evaluasi visual gabungan dari plot korelogram ACF dan PACF sisaan model ARIMA(1,1,1) menunjukkan perbaikan kinerja yang signifikan dibandingkan model ARIMA(0,1,1). Seluruh batang koefisien autokorelasi (ACF) maupun autokorelasi parsial (PACF) dari lag awal hingga lag akhir berada secara konsisten di bawah rentang batas kritis garis putus-putus biru, yang mengindikasikan bahwa galat sisaan telah saling bebas.

Histogram of model.arima11\$residua



Visualisasi kurva densitas normal teoretis (dnorm) menunjukkan tingkat kelekatan (*goodness-of-fit*) yang

cukup presisi di atas sebaran histogram frekuensi sisaan model ARIMA(1,1,1). Struktur histogram sampel memperlihatkan profil sebaran yang cenderung simetris dan seimbang di sekitar nilai rata-rata nol, yang mengindikasikan bahwa asumsi normalitas sisaan telah terpenuhi dengan baik.


Karakteristik sisaan ini diperkuat secara statistik melalui pengujian independensi galat menggunakan fungsi `Box.test()` dengan spesifikasi `type="Ljung-Box"`. Hasil pengujian menghasilkan nilai statistik $\chi^2 = 27.649$ dengan derajat bebas $df = 18$ dan nilai $p\text{-value} = 0.0676$. Karena $p\text{-value} > 0.05$, maka hipotesis nol gagal ditolak, yang berarti sisaan model ARIMA(1,1,1) bersifat acak murni (white noise) dan model dinyatakan layak.

4.4.3 Model ARIMA(2,1,1)

Melalui penambahan orde komponen autoregressive, fungsi `arima(wt.cctv, order=c(2, 1, 1))` menghasilkan taksiran koefisien $ar1 = -0.8519$, $ar2 = -0.1214$, dan $ma1 = -1.0000$. Model ini mencatat nilai varians sisaan $\sigma^2 = 26.81$, log likelihood = -91.64, serta AIC = 191.29. Rumusan persamaan formal model ARIMA(2,1,1) dijabarkan sebagai berikut:


$$(y_t - y_{t-1}) = -0.8519(y_{t-1} - y_{t-2}) - 0.1214(y_{t-2} - y_{t-3}) + \epsilon_t - 1.0000\epsilon_{t-1}$$

Evaluasi sisaan model dipetakan melalui fungsi plot berikut:



Gabungan analisis visual grafik korelogram ACF dan PACF dari komponen sisaan model ARIMA(2,1,1) memperlihatkan pemotongan koefisien galat yang terkendali dengan sangat baik. Baik koefisien autokorelasi maupun koefisien parsialnya secara serempak terkunci di dalam ruang batas interval acak statistik, menandakan tidak ada kebocoran informasi temporal pada galat.

Histogram of model.arima211\$residua



Visualisasi kurva densitas normal teoretis (dnorm) menunjukkan tingkat kelekatan (*goodness-of-fit*) yang cukup presisi di atas sebaran histogram frekuensi sisaan model ARIMA(2,1,1). Struktur histogram sampel memperlihatkan profil sebaran yang cenderung simetris dan seimbang di sekitar nilai rata-rata nol, yang mengindikasikan bahwa asumsi normalitas sisaan telah terpenuhi dengan baik. Karakteristik sisaan ini diperkuat secara statistik melalui pengujian independensi galat menggunakan fungsi `Box.test()` dengan spesifikasi `type="Ljung-Box"`. Hasil pengujian menghasilkan nilai statistik $\chi^2 = 26.503$ dengan derajat bebas $df = 17$ dan nilai $p\text{-value} = 0.06576$. Karena $p\text{-value} > 0.05$, maka hipotesis nol gagal ditolak, yang berarti sisaan model ARIMA(2,1,1) dinyatakan telah bersifat acak murni (white noise), sehingga model ini dinyatakan valid secara statistik.


4.4.4 Model ARIMA(1,1,2)

Estimasi parameter model campuran melalui fungsi `arima(wt.cctv, order=c(1, 1, 2))` menghasilkan koefisien $ar1 = -0.6644$, $ma1 = -1.2308$, dan $ma2 = 0.2309$, dengan nilai $\sigma^2 = 26.5$ dan $AIC = 191.15$.


Persamaan formal untuk model ARIMA(1,1,2) didefinisikan sebagai berikut:

$$(y_t - y_{t-1}) = -0.6644(y_{t-1} - y_{t-2}) + \epsilon_t - 1.2308\epsilon_{t-1} + 0.2309\epsilon_{t-2}$$

Evaluasi kelayakan sisaan dianalisis melalui fungsi plot berikut



Analisis visual terpadu pada plot korelogram ACF dan PACF sisaan model ARIMA(1,1,2) menunjukkan kestabilan pergerakan galat jangka pendek. Tidak ditemukan adanya lonjakan batang koefisien korelasi murni maupun parsial yang menembus garis signifikansi putus-putus biru, membuktikan galat bergerak secara acak.



Visualisasi kurva densitas normal teoretis (dnorm) menunjukkan tingkat kelekatan (*goodness-of-fit*) yang cukup presisi di atas sebaran histogram frekuensi sisaan model ARIMA(1,1,2). Struktur histogram sampel memperlihatkan profil sebaran yang cenderung simetris dan seimbang di sekitar nilai rata-rata nol, yang mengindikasikan bahwa asumsi normalitas sisaan telah terpenuhi dengan baik.


Karakteristik sisaan ini diperkuat secara statistik melalui pengujian independensi galat menggunakan fungsi `Box.test()` dengan spesifikasi `type="Ljung-Box"`. Hasil pengujian menghasilkan nilai statistik $\chi^2 = 25.356$ dengan derajat bebas $df = 17$ dan nilai $p\text{-value} = 0.08703$. Karena $p\text{-value} > 0.05$, maka hipotesis nol gagal ditolak, yang berarti sisaan model ARIMA(1,1,2) dinyatakan telah bersifat acak murni (white noise).

4.4.5 Model ARIMA(2,1,2)

Estimasi parameter model campuran integrasi orde tertinggi dijalankan melalui fungsi `arima(wt.cctv, order=c(2, 1, 2))`. Komputasi menghasilkan nilai koefisien $ar1 = -0.0935$, $ar2 = 0.4335$, $ma1 = -1.9844$, dan $ma2 = 0.9999$, dengan nilai $\sigma^2 = 22.16$ dan $AIC = 190.78$. Rumusan persamaan formal model ARIMA(2,1,2) didefinisikan sebagai berikut:


$$(y_t - y_{t-1}) = -0.0935(y_{t-1} - y_{t-2}) + 0.4335(y_{t-2} - y_{t-3}) + \epsilon_t - 1.9844\epsilon_{t-1} + 0.9999\epsilon_{t-2}$$

Pengujian kelayakan sisaan model dianalisis secara rigid melalui plot berikut:



Grafik fungsi ACF dan PACF dari sisaan model ARIMA(2,1,2) dievaluasi secara bersamaan untuk memastikan kekuatan struktural model berorde tinggi. Hasil plot memperlihatkan pemotongan struktur korelasi galat yang bersih, di mana seluruh nilai koordinat lag terisolasi secara sempurna di bawah rentang selang kepercayaan statistik garis biru.

Histogram of model.arima212\$residuals



Visualisasi kurva densitas normal teoretis (`dnorm`) menunjukkan tingkat kelekatan (*goodness-of-fit*) yang cukup presisi di atas sebaran histogram frekuensi sisaan model ARIMA(2,1,2). Struktur histogram sampel memperlihatkan profil sebaran yang cenderung simetris dan seimbang di sekitar nilai rata-rata nol, yang mengindikasikan bahwa asumsi normalitas sisaan telah terpenuhi dengan baik.

Karakteristik sisaan ini diperkuat secara statistik melalui pengujian independensi galat menggunakan fungsi `Box.test()` dengan spesifikasi `type="Ljung-Box"`. Hasil pengujian menghasilkan nilai statistik $\chi^2 = 25.077$ dengan derajat bebas $df = 16$ dan nilai $p\text{-value} = 0.06847$. Karena $p\text{-value} > 0.05$, maka

hipotesis nol gagal ditolak, yang berarti sisaan model ARIMA(2,1,2) dinyatakan telah bersifat acak murni (white noise) dan dapat dimasukkan secara valid ke dalam proses seleksi model terbaik bersama jajaran kandidat lainnya.

Berikut adalah draf terstruktur untuk bagian **4.5 Pemilihan Model Terbaik dan Peramalan (*Forecasting*)** berdasarkan hasil output program terbaru Anda. Bagian ini disusun dengan gaya akademis yang rigid, analitis, dan mendalam untuk menutup Bab 4 laporan UAS Anda.

4.5 Pemilihan Model Terbaik dan Peramalan (*Forecasting*)

Tahap akhir dari siklus pemodelan menggunakan metodologi Box-Jenkins adalah melakukan komparasi performa dan menetapkan satu model paling optimal di antara seluruh rangkaian kandidat model yang telah diestimasi. Instrumen utama yang digunakan dalam proses seleksi ini adalah nilai kriteria informasi kriteria (*Akaike Information Criterion*). Nilai AIC bertindak sebagai penilai keseimbangan antara tingkat keakuratan kecocokan data (*goodness of fit*) dengan kesederhanaan struktur parameter model (*prinsip parsimoni*).

Untuk mempermudah proses visualisasi komparasi, nilai numerik AIC dari ke-13 kandidat model yang dieksekusi melalui fungsi AIC() di RStudio dirangkum pada Tabel 4.1 berikut:

No	Model	Spesifikasi Orde (p,d,q)	Nilai Informasi AIC	Status Kelayakan
1	AR(1)	(1, 0, 0)	190.3543	Layak
2	AR(2)	(2, 0, 0)	191.6424	Layak
3	MA(1)	(0, 0, 1)	191.7258	Layak
4	MA(2)	(0, 0, 2)	191.8654	Layak
5	ARMA(1,1)	(1, 0, 1)	190.4828	Layak
6	ARMA(1,2)	(1, 0, 2)	190.3229	Layak
7	ARMA(2,1)	(2, 0, 1)	188.5862	Sangat Layak (Model Terbaik)
8	ARMA(2,2)	(2, 0, 2)	190.4685	Layak
9	ARIMA(0,1,1)	(0, 1, 1)	212.7671	Tidak Layak (<i>p-value</i> Ljung-Box < 0.05)


10	ARIMA(1,1,1)	(1, 1, 1)	189.7213	Layak
11	ARIMA(2,1,1)	(2, 1, 1)	191.2859	Layak
12	ARIMA(1,1,2)	(1, 1, 2)	191.1537	Layak
13	ARIMA(2,1,2)	(2, 1, 2)	190.7835	Layak

Tabel 4.1 Komparasi Nilai Kriteria Informasi AIC Sekumpulan Model Kandidat Berdasarkan data komparasi yang tersaji pada Tabel 4.1, terlihat bahwa nilai AIC terkecil di antara seluruh model yang diuji dihasilkan oleh model campuran **ARMA(2,1)** dengan nilai AIC sebesar **188.5862**. Sesuai landasan teori, model dengan nilai kriteria informasi terendah menjamin struktur parameter yang paling efisien dalam mengunci pergerakan data tanpa mengalami gejala *overfitting*.

Meskipun model ARIMA(1,1,1) menghasilkan nilai AIC yang cukup rendah (189.7213), model tersebut tetap tidak dipilih karena secara struktural kalah kompetitif dibandingkan model ARMA(2,1) yang bekerja langsung pada level data asli stasioner. Oleh karena itu, model ARMA(2,1) secara resmi ditetapkan sebagai **Model Terbaik** oleh Kelompok 6 untuk digunakan pada tahapan evaluasi kurva dan proyeksi masa depan.

4.5.1 Analisis Kurva Nilai Kecocokan (*Fitted Values*) Model Terbaik

Setelah model ARMA(2,1) terpilih, dilakukan ekstraksi nilai prediksi sampel (*fitted values*) menggunakan fungsi fitted() untuk membandingkan performa pemodelan secara internal terhadap data aktual melalui plot berikut:




Pembahasan Plot 41: Grafik evaluasi performa model di atas menampilkan titik-titik data aktual volume harian kendaraan roda 4 (berwarna hitam) yang ditumpangkan secara langsung dengan garis kontinu nilai kecocokan (*fitted values*) dari model ARMA(2,1). Melalui pengamatan visual, kurva nilai *fitted* menunjukkan fleksibilitas struktural yang sangat baik di mana garis pemodelan mampu melintasi dan mengikuti arah fluktuasi naik-turun data riil secara proporsional. Keselarasan pergerakan kurva ini mengonfirmasi secara visual bahwa kombinasi dua parameter *autoregressive* (ϕ_1, ϕ_2) dan satu parameter

moving average (θ_1) telah sukses merekam pola historis volume lalu lintas di Simpang Wardhani.

4.5.2 Proyeksi Peramalan Jangka Pendek (*Forecasting*)

Fungsi analisis diakhiri dengan melakukan proyeksi peramalan volume kendaraan roda 4 untuk 7 periode ke depan (hari ke-32 hingga hari ke-38) menggunakan fungsi `forecast(best.model, h=7)`. Visualisasi kurva peramalan beserta rentang ketidakpastiannya dieksekusi melalui fungsi plot berikut:

recasts from ARIMA(2,0,1) with non-zero



Pembahasan Plot 42: Grafik yang dihasilkan dari fungsi `plot(best.forecast)` menampilkan kurva proyeksi nilai peramalan masa depan harian yang bergerak dinamis melintasi waktu. Kurva prediksi ini dikelilingi oleh area bayangan berwarna abu-abu tua yang merepresentasikan batas interval kepercayaan (*confidence interval*) 80%, serta area abu-abu muda yang melambangkan batas interval kepercayaan 95%.

Berdasarkan hasil numerik output program, nilai *Point Forecast* pada hari ke-32 diprediksi berada pada angka 6.38 kendaraan, lalu bergerak turun secara sinusoidal teredam menuju nilai negatif di beberapa titik (seperti -3.46 pada hari ke-33), sebelum akhirnya beresilasi stabil mendekati nilai rata-rata jangka panjangnya di sekitar angka 0 hingga 2 kendaraan per hari.

Munculnya nilai perkiraan titik (*point forecast*) negatif pada model peramalan data volume kendaraan dalam praktik riil ini terjadi sebagai konsekuensi matematis dari struktur parameter model ARMA(2,1) yang memiliki akar karakteristik kompleks teredam, sehingga memicu osilasi tajam ke bawah ketika memproyeksikan data yang memiliki varians lokal tinggi.

Kendati demikian, dalam interpretasi fisik manajemen lalu lintas, nilai prediksi titik yang berada di bawah angka nol tersebut secara logis dibaca sebagai kondisi volume kendaraan roda 4 yang sangat sepi (mendekati 0 kendaraan) pada interval durasi kritis pukul 20.00-20.03 WIB. Pengambil kebijakan dapat mengacu pada batas atas interval kepercayaan 95% (*Hi 95*) yang bernilai positif (berada di kisaran 10 hingga 17 kendaraan per hari) sebagai acuan batas maksimum skenario pergerakan arus lalu lintas roda 4 yang memotong ke kanan di Simpang Wardhani pada periode mendatang.

BAB 5

KESIMPULAN DAN SARAN

5.1 Kesimpulan

Berdasarkan hasil analisis, pembahasan, dan seluruh rangkaian pengujian model runtun waktu yang telah dilakukan terhadap data volume lalu lintas kendaraan roda 4 yang berbelok ke kanan di Simpang Wardhani melalui rekaman CCTV resmi (<https://cctv.jogiaprov.go.id/>), peneliti menarik beberapa kesimpulan ilmiah sebagai berikut:

22. Karakteristik awal data aktual volume harian kendaraan roda 4 secara visual menunjukkan fluktuasi yang stabil dan konstan di sekitar nilai tengahnya ($mean = 22,03$ kendaraan) tanpa adanya unsur tren jangka panjang yang ekstrem. Grafik Fungsi Autokorelasi (ACF) data asli langsung meluruh secara tajam menuju nol (*die out rapidly*) sejak lag awal, membuktikan secara statistik bahwa data mentah hasil observasi mandiri ini sudah berada dalam kondisi stasioner.
23. Melalui evaluasi mendalam terhadap 13 model kandidat yang diuji (meliputi rumpun model AR murni, MA murni, campuran ARMA tanpa pembedaan, serta rumpun model ARIMA berorde $d=1$), model **ARMA(2,1)** secara resmi ditetapkan sebagai **Model Terbaik**. Model ini menghasilkan nilai kriteria informasi terkecil dengan nilai AIC sebesar **188,5862**.
24. Hasil pengujian diagnostik sisaan (*residual checking*) membuktikan bahwa model ARMA(2,1) sangat valid dan memadai (*adequate*). Pengujian independensi menggunakan Ljung-Box Test menghasilkan nilai probabilitas tertinggi di antara model layak lainnya, yaitu $p\text{-value} = 0,4092$ ($> 0,05$), yang berarti sisaan model telah terisolasi sempurna menjadi komponen acak murni (*white noise*). Selain itu, grafik histogram sisaan menunjukkan bentuk lonceng simetris yang selaras dengan kurva normal teoretis, mengonfirmasi terpenuhinya asumsi normalitas.
25. Proyeksi peramalan (*forecasting*) untuk 7 hari ke depan (hari ke-32 hingga hari ke-38) menggunakan model terbaik ARMA(2,1) menunjukkan pola pergerakan sinusoidal teredam yang bergerak konvergen menuju rata-rata jangka panjangnya. Munculnya nilai estimasi titik (*point forecast*) negatif pada beberapa periode ke depan dibaca secara logis sebagai indikasi kondisi arus lalu lintas kendaraan roda 4 yang sangat sepi (mendekati 0 kendaraan) pada interval durasi kritis pukul 20.00–20.03 WIB.

5.2 Saran

Guna pengembangan analisis dan pemanfaatan hasil penelitian yang lebih optimal di masa mendatang, peneliti mengajukan beberapa saran akademis dan praktis sebagai berikut:

17. **Bagi Peneliti Selanjutnya (Pengembangan Akademis):** Mengingat varians lokal data harian volume kendaraan di Simpang Wardhani cukup tinggi, penelitian berikutnya disarankan untuk memperpanjang rentang waktu pengambilan sampel (misalnya menjadi 2 atau 3 bulan) atau memperluas durasi interval pengamatan per hari agar model dapat menangkap memori jangka panjang data secara lebih komprehensif. Selain itu, dapat dipertimbangkan penggunaan model non-linear seperti ARCH/GARCH apabila ditemukan indikasi heteroskedastisitas pada varians galat.
18. **Bagi Instansi Terkait (Penerapan Praktis):** Dinas Perhubungan atau pihak kepolisian daerah setempat dapat memanfaatkan hasil proyeksi peramalan ini sebagai acuan prediktif jangka pendek dalam menyusun skenario manajemen lalu lintas. Mengingat pada jam-jam tersebut volume

kendaraan roda 4 yang memotong jalan ke kanan diprediksi berada pada titik paling minimum (sangat sepi), pengaturan durasi lampu lalu lintas (*traffic light*) hijau untuk jalur tersebut dapat dikurangi secara dinamis guna memprioritaskan dan mengurai kepadatan pada arus jalur utama lainnya yang lebih padat.

DAFTAR PUSTAKA

- Andila, P. A. (2025). Penerapan model ARMA (Autoregressive Moving Average) dalam meramalkan harga cabai di Kota Bukittinggi. *JITET (Jurnal Informatika dan Teknik Elektro Terapan)*, 13(2), 223–231. [JITET](#) [1, 2]
- Anggorowati, M. A., & Monika, A. K. (2019). Aplikasi model functional ARMA process terhadap data arus lalu lintas. *Jurnal Aplikasi Statistika & Komputasi Statistik*, 11(1), 65–72. [3]
- Gemare, E., Kleden, M. A., Sinu, E. B., & Ginting, K. B. (2025). Analisis time series pada jumlah keberangkatan penumpang di Bandara El Tari Kupang menggunakan ARIMA Box-Jenkins. *Prosiding Seminar Nasional Sainstek VII 2025*, 270–285.
- Khaira, U., & Aulia, B. (2024). Komparasi peramalan ARIMA dan RNN pada tunggakan peserta BPJS Kesehatan Cabang Jambi. *Jurnal Pepadun*, 5(3), 262–274.
- Maharsi, I. R., Mukid, M. A., & Wilandari, Y. (2017). Peramalan jumlah kecelakaan di Kota Semarang tahun 2017 menggunakan metode runtun waktu (Studi kasus: Data jumlah kecelakaan lalu lintas di Kota Semarang periode Januari 2012 - Desember 2016). *Jurnal Gaussian*, 6(3), 355–364.
- Maswar. (2017). Analisis time series model ARMA untuk memprediksi jumlah santri PP Salafiyah Syafi'iyah Sukorejo 2017-2021. *Jurnal Lisan Al-Hal*, 11(1), 59–86. [4]
- Montgomery, D. C., Jennings, C. L., & Kulahci, M. (2015). *Introduction to time series analysis and forecasting* (2nd ed.). Wiley.
- Nurfitri, Yundari, & Martha, S. (2020). Pemodelan data runtun waktu dengan ARIMAX. *Buletin Ilmiah Mat. Stat. dan Terapannya (Bimaster)*, 09(1), 129–136.
- Shadiq, A. M. F., Irwan, & Nurfadilah, K. (2025). Analisis runtun waktu untuk peramalan banyaknya kejadian kecelakaan lalu lintas di Kabupaten Soppeng. *Jurnal Matematika dan Statistika serta Aplikasinya*, 13(1), 57–68.
- Sumarjaya, I. W., Srinadi, I. G. A. M., & Susilawati, M. (2018). *Kuliah 4: Model-model deret waktu stasioner* [Materi Ajar]. Program Studi Matematika, Universitas Udayana.
- Vulandari, R. T., & Parwitasari, T. A. (2018). Perbandingan model AR(1), ARMA (1,1), dan ARIMA (1,1,1) pada prediksi tinggi muka air Sungai Bengawan Solo pada pos pemantauan Jurug. *MUST: Journal of Mathematics Education, Science and Technology*, 3(1), 46–56. [5]

LAMPIRAN

INPUT

```
R
getwd()
setwd("C:/Users/USER/Documents/R/Time series")

# UAS TIME SERIES
# DATA CCTV SIMPANG WARDHANI

library(TTR)
library(forecast)

# INPUT DATA
cctv.data <- read.csv("Kelompok 6 Data CCTV Simpang Wardhani View Timur.csv", skip = 7,
header = TRUE, sep = ",")
cctv.ts <- ts(cctv.data[,2])

# PLOT DATA
plot(cctv.data[,2],type="o",pch=16,cex=.5,xlab="hari",ylab="Jumlah Kendaraan")

# KESTASIONERAN DATA
cctv.SMA3 <- SMA(cctv.ts,n=3)
plot.ts(cctv.SMA3)

cctv.SMA8 <- SMA(cctv.ts,n=8)
plot.ts(cctv.SMA8)

acf(cctv.ts,main="ACF Sebelum differencing")

pacf(cctv.ts, main="PACF Sebelum differencing")
ndiffs(cctv.ts)
#DIFFERENCING (d=1)
wt.cctv <- diff(cctv.ts,differences=1)
plot.ts(wt.cctv)

# ACF PACF DIFFERENCING
par(mfrow=c(1,2))

acf(wt.cctv,lag.max=20,type="correlation",main="ACF w(t)")
pacf(wt.cctv,lag.max=20,main="PACF w(t)")

# MODEL MA(1)
model.mal <- arima(wt.cctv,order=c(0,0,1))
model.mal
forecast.mal <- forecast(model.mal,h=7)
acf(model.mal$residuals,lag.max=20)
pacf(model.mal$residuals,lag.max=20)
Box.test(model.mal$residuals,lag=20,fitdf=1,type="Ljung-Box")
hist(model.mal$residuals,freq=FALSE,breaks=15)
curve(dnorm(x, mean=mean(model.mal$residuals),
sd=sd(model.mal$residuals)),col=2,lty=2,lwd=2,add=TRUE)

# MODEL MA(2)
```



```

model.ma2 <- arima(wt.cctv,order=c(0,0,2))
model.ma2
forecast.ma2 <- forecast(model.ma2,h=7)
acf(model.ma2$residuals,lag.max=20)
pacf(model.ma2$residuals,lag.max=20)
Box.test(model.ma2$residuals,lag=20,fitdf=2,type="Ljung-Box")
hist(model.ma2$residuals,freq=FALSE,breaks=15)
curve(dnorm(x,mean=mean(model.ma2$residuals),
                    sd=sd(model.ma2$residuals)),col=2,lty=2,lwd=2,add=TRUE)

# MODEL AR(1)
model.ar1 <- arima(wt.cctv,order=c(1,0,0))
model.ar1
forecast.ar1 <- forecast(model.ar1,h=7)
acf(model.ar1$residuals,lag.max=20)
pacf(model.ar1$residuals,lag.max=20)
Box.test(model.ar1$residuals,lag=20,fitdf=1,type="Ljung-Box")
hist(model.ar1$residuals,freq=FALSE,breaks=15)
curve(dnorm(x,mean=mean(model.ar1$residuals),
                    sd=sd(model.ar1$residuals)),col=2,lty=2,lwd=2,add=TRUE)

# MODEL AR(2)
model.ar2 <- arima(wt.cctv,order=c(2,0,0))
model.ar2
forecast.ar2 <- forecast(model.ar2,h=7)
acf(model.ar2$residuals,lag.max=20)
pacf(model.ar2$residuals,lag.max=20)
Box.test(model.ar2$residuals,lag=20,fitdf=2,type="Ljung-Box")
hist(model.ar2$residuals,freq=FALSE,breaks=15)
curve(dnorm(x,mean=mean(model.ar2$residuals),
                    sd=sd(model.ar2$residuals)),col=2,lty=2,lwd=2,add=TRUE)

# MODEL ARMA(1,1)
model.arma11 <- arima(wt.cctv,order=c(1,0,1))
model.arma11
forecast.arma11 <- forecast(model.arma11,h=7)
acf(model.arma11$residuals,lag.max=20)
pacf(model.arma11$residuals,lag.max=20)
Box.test(model.arma11$residuals,lag=20,fitdf=2,type="Ljung-Box")
hist(model.arma11$residuals,freq=FALSE,breaks=15)
curve(dnorm(x,mean=mean(model.arma11$residuals),
                    sd=sd(model.arma11$residuals)),col=2,lty=2,lwd=2,add=TRUE)

# MODEL ARMA(1,2)
model.arma12 <- arima(wt.cctv,order=c(1,0,2))
model.arma12
forecast.arma12 <- forecast(model.arma12,h=7)
acf(model.arma12$residuals,lag.max=20)
pacf(model.arma12$residuals,lag.max=20)
Box.test(model.arma12$residuals,lag=20,fitdf=3,type="Ljung-Box")
hist(model.arma12$residuals,freq=FALSE,breaks=15)
curve(dnorm(x,mean=mean(model.arma12$residuals),
                    sd=sd(model.arma12$residuals)),col=2,lty=2,lwd=2,add=TRUE)

# MODEL ARMA(2,1)
model.arma21 <- arima(wt.cctv,order=c(2,0,1))

```

```

model.arma21
forecast.arma21 <- forecast(model.arma21,h=7)
acf(model.arma21$residuals,lag.max=20)
pacf(model.arma21$residuals,lag.max=20)
Box.test(model.arma21$residuals,lag=20,fitdf=3,type="Ljung-Box")
hist(model.arma21$residuals,freq=FALSE,breaks=15)
curve(dnorm(x,mean=mean(model.arma21$residuals),
                    sd=sd(model.arma21$residuals)),col=2,lty=2,lwd=2,add=TRUE)

# MODEL ARMA(2,2)
model.arma22 <- arima(wt.cctv,order=c(2,0,2))
model.arma22
forecast.arma22 <- forecast(model.arma22,h=7)
acf(model.arma22$residuals,lag.max=20)
pacf(model.arma22$residuals,lag.max=20)
Box.test(model.arma22$residuals,lag=20,fitdf=4,type="Ljung-Box")
hist(model.arma22$residuals,freq=FALSE,breaks=15)
curve(dnorm(x,mean=mean(model.arma22$residuals),
                    sd=sd(model.arma22$residuals)),col=2,lty=2,lwd=2,add=TRUE)

#ARIMA MODELING
# MODEL ARIMA(0,1,1)
model.arima011 <- arima(wt.cctv,order=c(0,1,1))
model.arima011
forecast.arima011 <- forecast(model.arima011,h=7)
acf(model.arima011$residuals,lag.max=20)
pacf(model.arima011$residuals,lag.max=20)
Box.test(model.arima011$residuals,lag=20,fitdf=1,type="Ljung-Box")
hist(model.arima011$residuals,freq=FALSE,breaks=15)
curve(dnorm(x,mean=mean(model.arima011$residuals),
                    sd=sd(model.arima011$residuals)),col=2,lty=2,lwd=2,add=TRUE)

# MODEL ARIMA(1,1,1)
model.arima111 <- arima(wt.cctv,order=c(1,1,1))
model.arima111
forecast.arima111 <- forecast(model.arima111,h=7)
acf(model.arima111$residuals)
pacf(model.arima111$residuals)
Box.test(model.arima111$residuals,lag=20,fitdf=2,type="Ljung-Box")
hist(model.arima111$residuals,freq=FALSE,breaks=15)
curve(dnorm(x,mean=mean(model.arima111$residuals),
                    sd=sd(model.arima111$residuals)),col=2,lty=2,lwd=2,add=TRUE)

# MODEL ARIMA(2,1,1)
model.arima211 <- arima(wt.cctv,order=c(2,1,1))
model.arima211
forecast.arima211 <- forecast(model.arima211,h=7)
acf(model.arima211$residuals)
pacf(model.arima211$residuals)
Box.test(model.arima211$residuals,lag=20,fitdf=3,type="Ljung-Box")
hist(model.arima211$residuals,freq=FALSE,breaks=15)
curve(dnorm(x,mean=mean(model.arima211$residuals),
                    sd=sd(model.arima211$residuals)),col=2,lty=2,lwd=2,add=TRUE)

# MODEL ARIMA(1,1,2)
model.arima112 <- arima(wt.cctv,order=c(1,1,2))
model.arima112

```

```

forecast.arima112 <- forecast(model.arima112,h=7)
acf(model.arima112$residuals)
pacf(model.arima112$residuals)
Box.test(model.arima112$residuals,lag=20,fitdf=3,type="Ljung-Box")
hist(model.arima112$residuals,freq=FALSE,breaks=15)
curve(dnorm(x,mean=mean(model.arima112$residuals),
                    sd=sd(model.arima112$residuals)), col=2,lty=2,lwd=2,add=TRUE)

# MODEL ARIMA(2,1,2)
model.arima212 <- arima(wt.cctv,order=c(2,1,2))
model.arima212
forecast.arima212 <- forecast(model.arima212,h=7)
acf(model.arima212$residuals)
pacf(model.arima212$residuals)
Box.test(model.arima212$residuals,lag=20,fitdf=4,type="Ljung-Box")
hist(model.arima212$residuals,freq=FALSE,breaks=15)
curve(dnorm(x, mean=mean(model.arima212$residuals),
                    sd=sd(model.arima212$residuals)), col=2,lty=2,lwd=2,add=TRUE)

# PERBANDINGAN AIC
AIC(model.ar1)
AIC(model.ar2)
AIC(model.ma1)
AIC(model.ma2)
AIC(model.arma11)
AIC(model.arma12)
AIC(model.arma21)
AIC(model.arma22)
AIC(model.arima011)
AIC(model.arima111)
AIC(model.arima211)
AIC(model.arima112)
AIC(model.arima212)

# MODEL TERBAIK
best.model <- model.arma21

# FITTED MODEL TERBAIK
fit.best <- as.vector(fitted(best.model))
plot(cctv.data[,2],type="p",pch=16,cex=.5,xlab="hari",ylab="Jumlah Kendaraan")
lines(fit.best)
legend("topright",c("Data Aktual","Fitted"),pch=c(16,NA),lwd=c(NA,1))

# FORECAST MODEL TERBAIK
best.forecast <- forecast(best.model,h=7)
best.forecast
plot(best.forecast)

```

OUTPUT

```

R
> getwd()
[1] "C:/Users/USER/Documents/R/Time series"
> setwd("C:/Users/USER/Documents/R/Time series")
>
> # UAS TIME SERIES

```

```

> # DATA CCTV SIMPANG WARDHANI
>
> library(TTR)
> library(forecast)
>
> # INPUT DATA
> cctv.data <- read.csv("Kelompok 6 Data CCTV Simpang Wardhani View Timur.csv", skip =
7, header = TRUE, sep = ",")
> cctv.ts <- ts(cctv.data[,2])
>
> # PLOT DATA
> plot(cctv.data[,2], type="o", pch=16, cex=.5, xlab="hari", ylab="Jumlah Kendaraan")
>
> # KESTASIONERAN DATA
> cctv.SMA3 <- SMA(cctv.ts, n=3)
> plot.ts(cctv.SMA3)
>
> cctv.SMA8 <- SMA(cctv.ts, n=8)
> plot.ts(cctv.SMA8)
>
> acf(cctv.ts, main="ACF Sebelum differencing")
>
> pacf(cctv.ts, main="PACF Sebelum differencing")
> ndiffs(cctv.ts)
[1] 0
> #DIFFERENCING (d=1)
> wt.cctv <- diff(cctv.ts, differences=1)
> plot.ts(wt.cctv)
>
> # ACF PACF DIFFERENCING
> par(mfrow=c(1,2))
>
> acf(wt.cctv, lag.max=20, type="correlation", main="ACF w(t)")
> pacf(wt.cctv, lag.max=20, main="PACF w(t)")
>
> # MODEL MA(1)
> model.mal <- arima(wt.cctv, order=c(0,0,1))
> model.mal

Call:
arima(x = wt.cctv, order = c(0, 0, 1))

Coefficients:
      mal  intercept
      -1.0000     -0.1645
s.e.    0.0933      0.1014

sigma^2 estimated as 25.5:  log likelihood = -92.86,  aic = 191.73
> forecast.mal <- forecast(model.mal, h=7)
> acf(model.mal$residuals, lag.max=20)
> pacf(model.mal$residuals, lag.max=20)
> Box.test(model.mal$residuals, lag=20, fitdf=1, type="Ljung-Box")

Box-Ljung test

data:  model.mal$residuals

```

```

X-squared = 32.655, df = 19, p-value = 0.02634

> hist(model.ma1$residuals,freq=FALSE,breaks=15)
> curve(dnorm(x, mean=mean(model.ma1$residuals),
+         sd=sd(model.ma1$residuals)),col=2,lty=2,lwd=2,add=TRUE)
>
> # MODEL MA(2)
> model.ma2 <- arima(wt.cctv,order=c(0,0,2))
> model.ma2

Call:
arima(x = wt.cctv, order = c(0, 0, 2))

Coefficients:
          ma1      ma2  intercept
      -1.2015   0.2015    -0.1589
s.e.    0.1812   0.1501     0.0800

sigma^2 estimated as 23.59:  log likelihood = -91.93,  aic = 191.87
> forecast.ma2 <- forecast(model.ma2,h=7)
> acf(model.ma2$residuals,lag.max=20)
> pacf(model.ma2$residuals,lag.max=20)
> Box.test(model.ma2$residuals,lag=20,fitdf=2,type="Ljung-Box")

      Box-Ljung test

data:  model.ma2$residuals
X-squared = 29.101, df = 18, p-value = 0.04716

> hist(model.ma2$residuals,freq=FALSE,breaks=15)
> curve(dnorm(x,mean=mean(model.ma2$residuals),
+         sd=sd(model.ma2$residuals)),col=2,lty=2,lwd=2,add=TRUE)
>
> # MODEL AR(1)
> model.ar1 <- arima(wt.cctv,order=c(1,0,0))
> model.ar1

Call:
arima(x = wt.cctv, order = c(1, 0, 0))

Coefficients:
          ar1  intercept
      -0.7620   -0.2495
s.e.    0.1095    0.5416

sigma^2 estimated as 26.53:  log likelihood = -92.18,  aic = 190.35
> forecast.ar1 <- forecast(model.ar1,h=7)
> acf(model.ar1$residuals,lag.max=20)
> pacf(model.ar1$residuals,lag.max=20)
> Box.test(model.ar1$residuals,lag=20,fitdf=1,type="Ljung-Box")

      Box-Ljung test

data:  model.ar1$residuals
X-squared = 26, df = 19, p-value = 0.1302

```

```

> hist(model.ar1$residuals,freq=FALSE,breaks=15)
> curve(dnorm(x,mean=mean(model.ar1$residuals),
+          sd=sd(model.ar1$residuals)),col=2,lty=2,lwd=2,add=TRUE)
>
> # MODEL AR(2)
> model.ar2 <- arima(wt.cctv,order=c(2,0,0))
> model.ar2

```

Call:

```
arima(x = wt.cctv, order = c(2, 0, 0))
```

Coefficients:

	ar1	ar2	intercept
	-0.8814	-0.1500	-0.2417
s.e.	0.1773	0.1764	0.4662

sigma^2 estimated as 25.86: log likelihood = -91.82, aic = 191.64

```

> forecast.ar2 <- forecast(model.ar2,h=7)
> acf(model.ar2$residuals,lag.max=20)
> pacf(model.ar2$residuals,lag.max=20)
> Box.test(model.ar2$residuals,lag=20,fitdf=2,type="Ljung-Box")

```

Box-Ljung test

data: model.ar2\$residuals

X-squared = 24.794, df = 18, p-value = 0.1307

```

> hist(model.ar2$residuals,freq=FALSE,breaks=15)
> curve(dnorm(x,mean=mean(model.ar2$residuals),
+          sd=sd(model.ar2$residuals)),col=2,lty=2,lwd=2,add=TRUE)
>
> # MODEL ARMA(1,1)
> model.arma11 <- arima(wt.cctv,order=c(1,0,1))
> model.arma11

```

Call:

```
arima(x = wt.cctv, order = c(1, 0, 1))
```

Coefficients:

	ar1	ma1	intercept
	-0.3256	-1.0000	-0.1579
s.e.	0.1733	0.1098	0.0735

sigma^2 estimated as 22.39: log likelihood = -91.24, aic = 190.48

```

> forecast.arma11 <- forecast(model.arma11,h=7)
> acf(model.arma11$residuals,lag.max=20)
> pacf(model.arma11$residuals,lag.max=20)
> Box.test(model.arma11$residuals,lag=20,fitdf=2,type="Ljung-Box")

```

Box-Ljung test

data: model.arma11\$residuals

X-squared = 30.112, df = 18, p-value = 0.03637

```

> hist(model.arma11$residuals,freq=FALSE,breaks=15)
> curve(dnorm(x,mean=mean(model.arma11$residuals),

```

```

+           sd=sd(model.arma11$residuals)),col=2,lty=2,lwd=2,add=TRUE)
>
> # MODEL ARMA(1,2)
> model.arma12 <- arima(wt.cctv,order=c(1,0,2))
> model.arma12

```

Call:

```
arima(x = wt.cctv, order = c(1, 0, 2))
```

Coefficients:

	ar1	ma1	ma2	intercept
	-0.7242	-0.5778	-0.4214	-0.1597
s.e.	0.1862	0.2376	0.2171	0.0766

sigma^2 estimated as 20.89: log likelihood = -90.16, aic = 190.32

```

> forecast.arma12 <- forecast(model.arma12,h=7)
> acf(model.arma12$residuals,lag.max=20)
> pacf(model.arma12$residuals,lag.max=20)
> Box.test(model.arma12$residuals,lag=20,fitdf=3,type="Ljung-Box")

```

Box-Ljung test

data: model.arma12\$residuals

X-squared = 29.202, df = 17, p-value = 0.03271

```

> hist(model.arma12$residuals,freq=FALSE,breaks=15)
> curve(dnorm(x,mean=mean(model.arma12$residuals),
+           sd=sd(model.arma12$residuals)),col=2,lty=2,lwd=2,add=TRUE)
>
> # MODEL ARMA(2,1)
> model.arma21 <- arima(wt.cctv,order=c(2,0,1))
> model.arma21

```

Call:

```
arima(x = wt.cctv, order = c(2, 0, 1))
```

Coefficients:

	ar1	ar2	ma1	intercept
	-0.1861	0.3562	-1.0000	-0.1711
s.e.	0.1787	0.1769	0.0926	0.1028

sigma^2 estimated as 20.08: log likelihood = -89.29, aic = 188.59

```

> forecast.arma21 <- forecast(model.arma21,h=7)
> acf(model.arma21$residuals,lag.max=20)
> pacf(model.arma21$residuals,lag.max=20)
> Box.test(model.arma21$residuals,lag=20,fitdf=3,type="Ljung-Box")

```

Box-Ljung test

data: model.arma21\$residuals

X-squared = 25.197, df = 17, p-value = 0.09039

```

> hist(model.arma21$residuals,freq=FALSE,breaks=15)
> curve(dnorm(x,mean=mean(model.arma21$residuals),
+           sd=sd(model.arma21$residuals)),col=2,lty=2,lwd=2,add=TRUE)
>

```

```

> # MODEL ARMA(2,2)
> model.arma22 <- arima(wt.cctv,order=c(2,0,2))
> model.arma22

Call:
arima(x = wt.cctv, order = c(2, 0, 2))

Coefficients:
      ar1      ar2      ma1      ma2  intercept
-0.2851  0.3266 -0.8886 -0.1114  -0.1695
s.e.    0.3346  0.2052   0.3232   0.3096   0.1000

sigma^2 estimated as 19.95:  log likelihood = -89.23,  aic = 190.47
> forecast.arma22 <- forecast(model.arma22,h=7)
> acf(model.arma22$residuals,lag.max=20)
> pacf(model.arma22$residuals,lag.max=20)
> Box.test(model.arma22$residuals,lag=20,fitdf=4,type="Ljung-Box")

      Box-Ljung test

data:  model.arma22$residuals
X-squared = 25.436, df = 16, p-value = 0.0625

> hist(model.arma22$residuals,freq=FALSE,breaks=15)
> curve(dnorm(x,mean=mean(model.arma22$residuals),
+          sd=sd(model.arma22$residuals)),col=2,lty=2,lwd=2,add=TRUE)
> #ARIMA MODELING
> # MODEL ARIMA(0,1,1)
> model.arima011 <- arima(wt.cctv,order=c(0,1,1))
> model.arima011

Call:
arima(x = wt.cctv, order = c(0, 1, 1))

Coefficients:
      ma1
-1.0000
s.e.    0.0868

sigma^2 estimated as 69.67:  log likelihood = -104.38,  aic = 212.77
> forecast.arima011 <- forecast(model.arima011,h=7)
> acf(model.arima011$residuals,lag.max=20)
> pacf(model.arima011$residuals,lag.max=20)
> Box.test(model.arima011$residuals,lag=20,fitdf=1,type="Ljung-Box")

      Box-Ljung test

data:  model.arima011$residuals
X-squared = 62.203, df = 19, p-value = 1.726e-06

> hist(model.arima011$residuals,freq=FALSE,breaks=15)
> curve(dnorm(x,mean=mean(model.arima011$residuals),
+          sd=sd(model.arima011$residuals)),col=2,lty=2,lwd=2,add=TRUE)
>
> # MODEL ARIMA(1,1,1)
> model.arima111 <- arima(wt.cctv,order=c(1,1,1))

```



```

> model.arima111

Call:
arima(x = wt.cctv, order = c(1, 1, 1))

Coefficients:
          ar1          ma1
      -0.7543   -1.0000
s.e.    0.1120    0.1007

sigma^2 estimated as 27.48:  log likelihood = -91.86,  aic = 189.72
> forecast.arima111 <- forecast(model.arima111,h=7)
> acf(model.arima111$residuals)
> pacf(model.arima111$residuals)
> Box.test(model.arima111$residuals,lag=20,fitdf=2,type="Ljung-Box")

Box-Ljung test

data:  model.arima111$residuals
X-squared = 27.649, df = 18, p-value = 0.0676

> hist(model.arima111$residuals,freq=FALSE,breaks=15)
> curve(dnorm(x,mean=mean(model.arima111$residuals),
+          sd=sd(model.arima111$residuals)),col=2,lty=2,lwd=2,add=TRUE)
>
> # MODEL ARIMA(2,1,1)
> model.arima211 <- arima(wt.cctv,order=c(2,1,1))
> model.arima211

Call:
arima(x = wt.cctv, order = c(2, 1, 1))

Coefficients:
          ar1          ar2          ma1
      -0.8519   -0.1214   -1.0000
s.e.    0.1833    0.1822    0.1058

sigma^2 estimated as 26.81:  log likelihood = -91.64,  aic = 191.29
> forecast.arima211 <- forecast(model.arima211,h=7)
> acf(model.arima211$residuals)
> pacf(model.arima211$residuals)
> Box.test(model.arima211$residuals,lag=20,fitdf=3,type="Ljung-Box")

Box-Ljung test

data:  model.arima211$residuals
X-squared = 26.503, df = 17, p-value = 0.06576

> hist(model.arima211$residuals,freq=FALSE,breaks=15)
> curve(dnorm(x,mean=mean(model.arima211$residuals),
+          sd=sd(model.arima211$residuals)),col=2,lty=2,lwd=2,add=TRUE)
>
> # MODEL ARIMA(1,1,2)
> model.arima112 <- arima(wt.cctv,order=c(1,1,2))
> model.arima112

```

```

Call:
arima(x = wt.cctv, order = c(1, 1, 2))

Coefficients:
          ar1          ma1          ma2
      -0.6644  -1.2308   0.2309
s.e.    0.1919   0.3402   0.3228

sigma^2 estimated as 26.5:  log likelihood = -91.58,  aic = 191.15
> forecast.arima112 <- forecast(model.arima112,h=7)
> acf(model.arima112$residuals)
> pacf(model.arima112$residuals)
> Box.test(model.arima112$residuals,lag=20,fitdf=3,type="Ljung-Box")

Box-Ljung test

data:  model.arima112$residuals
X-squared = 25.356, df = 17, p-value = 0.08703

> hist(model.arima212$residuals,freq=FALSE,breaks=15)
> curve(dnorm(x,mean=mean(model.arima112$residuals),
+         sd=sd(model.arima112$residuals)), col=2,lty=2,lwd=2,add=TRUE)
>
> # MODEL ARIMA(2,1,2)
> model.arima212 <- arima(wt.cctv,order=c(2,1,2))
> model.arima212

Call:
arima(x = wt.cctv, order = c(2, 1, 2))

Coefficients:
          ar1          ar2          ma1          ma2
      -0.0935   0.4335  -1.9844   0.9999
s.e.    0.1946   0.1888   0.1649   0.1650

sigma^2 estimated as 22.16:  log likelihood = -90.39,  aic = 190.78
> forecast.arima212 <- forecast(model.arima212,h=7)
> acf(model.arima212$residuals)
> pacf(model.arima212$residuals)
> Box.test(model.arima212$residuals,lag=20,fitdf=4,type="Ljung-Box")

Box-Ljung test

data:  model.arima212$residuals
X-squared = 25.077, df = 16, p-value = 0.06847




> hist(model.arima212$residuals,freq=FALSE,breaks=15)
> curve(dnorm(x, mean=mean(model.arima212$residuals),
+         sd=sd(model.arima212$residuals)), col=2,lty=2,lwd=2,add=TRUE)
>
> # PERBANDINGAN AIC
> AIC(model.ar1)
[1] 190.3543
> AIC(model.ar2)
[1] 191.6424
> AIC(model.ma1)

```


```

[1] 191.7258
> AIC(model.ma2)
[1] 191.8654
> AIC(model.arma11)
[1] 190.4828
> AIC(model.arma12)
[1] 190.3229
> AIC(model.arma21)
[1] 188.5862
> AIC(model.arma22)
[1] 190.4685
> AIC(model.arima011)
[1] 212.7671
> AIC(model.arima111)
[1] 189.7213
> AIC(model.arima211)
[1] 191.2859
> AIC(model.arima112)
[1] 191.1537
> AIC(model.arima212)
[1] 190.7835
>
> # MODEL TERBAIK
> best.model <- model.arma21
>
> # FITTED MODEL TERBAIK
> fit.best <- as.vector(fitted(best.model))
> plot(cctv.data[,2],type="p",pch=16,cex=.5,xlab="hari",ylab="Jumlah Kendaraan")
> lines(fit.best)
> legend("topright",c("Data Aktual","Fitted"),pch=c(16,NA),lwd=c(NA,1))
>
> # FORECAST MODEL TERBAIK
> best.forecast <- forecast(best.model,h=7)
> best.forecast
      Point Forecast      Lo 80      Hi 80      Lo 95      Hi 95
32      6.3884764    0.5576103 12.219342  -2.529064 15.30602
33     -3.4680483   -12.3790058  5.442909 -17.096182 10.16009
34      2.7789528    -6.7343006 12.292206 -11.770313 17.32822
35     -1.8944591   -11.8756191  8.086701 -17.159326 13.37041
36      1.2004094    -8.9327682 11.333587 -14.296948 16.69777
37     -1.0401909   -11.2697890  9.189407 -16.685011 14.60463
38      0.4791599    -9.7885305 10.746850 -15.223918 16.18224
> plot(best.forecast)



```




ACF Sebelum differencing




PACF Sebelum differencing




ACF w(t)




PACF w(t)




Histogram of model.ma1\$residuals




Series model.ma2\$residuals




Series model.ma1\$residuals




Series model.ma1\$residuals




Series model.ma2\$residuals




Histogram of model.ma2\$residuals







Series modelArma22\$residuals




Histogram of modelArma22\$residuals




Histogram of modelArima011\$residuals




Series modelArima111\$residuals




Series modelArima011\$residuals




Series modelArima011\$residuals




Series modelArima111\$residuals




Histogram of modelArima111\$residuals




Series modelArima211\$residuals




Series modelArima211\$residuals




Series modelArima112\$residuals




Histogram of modelArima112\$residuals




Histogram of modelArima211\$residuals




Series modelArima112\$residuals




Series modelArima212\$residuals



Series modelArima212\$residuals



Histogram of modelArima212\$residua



recasts from ARIMA(2,0,1) with non-zero

